

Bitácora 3

Universidad de Costa Rica

Escuela de Matemática

Departamento de Matemática y Ciencias Actuariales

Proyecto de Investigación

Análisis del cambio de la probabilidad de decremento ${}_nq_x^{(c)}$ para grupos etarios por causas de muerte de acuerdo a la clasificación ICD-10 en países de Centroamérica [2015, 2018].

Integrantes

Sebastián Miranda Ramírez C4H274

Benjamín Gutiérrez Padua C4F813

Kevin David Calderón Martínez C4D511

Gabriel de Jesús Chaves Esquivel C4E273

Profesor

Maikol Solís Chacón

2026

Bitácora 3

1. Parte de Planificación

1.2.1. Formulación metodológica del proyecto

La metodología del proyecto se construye alrededor de estimar la probabilidad actuarial de decremento por causa,

$${}_nq_{x,t}^{(c)} = P(T_{x,t} \leq n, J = c),$$

donde x representa el del grupo etario de cada persona y t el año calendario en el cual se encuentran,

$$x \in \{0, 1, 2, 3, 4, 5-9, 10-14, \dots, 90-94, 95+\}, \quad t \in \{2015, 2016, 2017, 2018\}$$

y c una categoría de causa de muerte según la ICD-10, de acuerdo con la clasificación definida en bitácoras anteriores. En particular, cuando el grupo etario se denote por su edad inicial, x también puede leerse como el extremo inferior del intervalo. Por ejemplo, para el grupo 30-34 se puede escribir $x = 30$ y asociar el intervalo $I_x = [30, 35)$, esta convención se usará al escribir las diversas fórmulas a estimar.

La variable aleatoria $T_{x,t}$ representa el tiempo futuro de vida de una persona perteneciente al grupo etario x durante el año calendario t y J es una variable aleatoria que indica la causa del decremento. Con esta convención, $q_{x,t}^{(c)}$ debe leerse como la probabilidad de morir por la causa c para una vida perteneciente al grupo etario x durante el año calendario t , bajo las intensidades estimadas para esa celda. Por ejemplo, si $x = 30-34$, entonces $q_{30-34,t}^{(c)}$ no se interpreta como la probabilidad exacta de una persona de edad puntual 30, 33.9 o 34.7, sino como el riesgo anual asociado al grupo etario completo 30-34 durante el año t . Asimismo se considera que para que alguien muera por la causa c primero debe no haber muerto por las otras $c - 1$ causas, de manera que estas se consideran “causas competidoras” e influyen en el cálculo de las diferentes probabilidades. Bowers et al. (1997) y Deshmukh (2012) presentan este tratamiento para las probabilidades de decremento.

Aunque el objeto de estudio también depende del país y del sexo, estas dimensiones se mantienen se omiten de la expresión para no sobrecargar la notación, en el momento de presentación de resultados se hará explícito el sexo y el país al que se esté refiriendo cada aseveración. De forma más general, la probabilidad podría escribirse como ${}_nq_{x,t,p,s}^{(c)}$, donde p representa el país y s el sexo.

Para la estimación de estas causas se deberá de recurrir a los datos disponibles en la WHO Mortality Database, los cuales se presenran de manera agregada, por tanto la unidad de análisis

será una celda definida por país y sexo dados, así como año calendario t , grupo etario x y causa de muerte c . Para cada celda se tendrá un conteo de defunciones,

$$D_{x,t}^{(c)},$$

obtenido de la WHO Mortality Database, y una exposición en años-persona,

$$E_{x,t},$$

aproximada mediante la población media o población a mitad de año, la cual es obtenida de la Population and live births Database, también de la WHO. Pitacco et al. (2009) validan esta aproximación para la exposición.

Antes de pasar a los enfoques de estimación, es necesario aclarar con mayor precisión los supuestos bajo los cuales se interpretará el objeto actuarial del proyecto. En este sentido, la notación actuarial general ${}_nq_{x,t}^{(c)}$ es útil para introducir la idea de probabilidad de decremento por causa, y además es cercana a la notación estándar utilizada en trabajos sobre probabilidades de decrementos múltiples. En una formulación actuarial más general, para trabajar con ${}_nq_{x',t'}^{(c)}$ se puede interpretar x' como una edad exacta y t' como un momento exacto del calendario. Sin embargo, en dichos trabajos se suele contar con maneras precisas de estimar las probabilidades ${}_nq_{x',t'}^{(c)}$, para al menos todos los x', t' enteros, de manera que mediante supuestos como fuerza de mortalidad constante en cada celda $[x', x' + 1)$ y $[t', t' + 1)$ se pueden estimar toda la familia de probabilidades ${}_nq_{x',t'}^{(c)}$, para x', t', n reales.

Sin embargo, en este trabajo no se cuenta con datos para todas las edades exactas x' ni para todos los momentos calendario t' , debido a la naturaleza agregada de la WHO Mortality Database. Los datos disponibles están agrupados por grupo etario y año calendario, a excepción de los primeros años de vida, donde sí aparecen de manera más desagregada. Por esta razón, en nuestro trabajo x no representa una edad exacta individual, sino que indexa el grupo etario al que pertenece la persona.

Por tanto, el supuesto de fuerza constante no se hará solamente sobre una celda del estilo $[x', x' + 1)$ y $[t', t' + 1)$ para edades exactas, sino sobre todo el intervalo de edad asociado al grupo etario durante un año calendario. Así, para un país y sexo fijados, si I_x representa el grupo etario asociado a x , y si t representa el año calendario, se asumirá que la fuerza de mortalidad por causa es constante dentro de la celda formada por grupo etario y año calendario. Es decir, si

$$I_x = [a_x, b_x),$$

entonces se supondrá que

$$\mu_{y,z}^{(c)} = \mu_{x,t}^{(c)}$$

para edades exactas $y \in I_x$ y momentos calendario $z \in [t, t+1)$, donde $\mu_{x,t}^{(c)}$ representa la intensidad o tasa central de mortalidad por la causa c para la celda definida por grupo etario x y año calendario t .

En el caso particular de grupos quinquenales, si el grupo se denota por su edad inicial y se escribe $I_x = [x, x+5)$, el supuesto anterior equivale a asumir que

$$\mu_{x+\xi_1, t+\xi_2}^{(c)} = \mu_{x,t}^{(c)}, \quad 0 \leq \xi_1 < 5, \quad 0 \leq \xi_2 < 1.$$

En otras palabras, $\mu_{x,t}^{(c)}$ no representa una intensidad propia de una edad exacta como 33.9, sino la intensidad estimada para todo el grupo etario x durante el año t . Por ejemplo, si $x = 30$ representa el grupo 30-34, entonces $\mu_{30,t}^{(c)}$ representa una única intensidad asociada al intervalo $I_{30} = [30, 35)$ durante el año calendario t .

Esta aclaración es importante porque ${}_nq_{x,t}^{(c)}$, para un horizonte general n , solo puede usarse directamente con una única intensidad de muerte cuando el intervalo considerado permanece dentro de la celda donde esa intensidad fue asumida constante. Si una persona tuviera una edad exacta $y \in I_x$ y se quisiera seguir durante n años usando solamente $\mu_{x,t}^{(c)}$, tendría que cumplirse al menos que

$$y + n \leq b_x.$$

Si esta condición no se cumple, la persona saldría del grupo etario I_x y entraría en otro grupo, por lo que ya no sería correcto usar únicamente la intensidad $\mu_{x,t}^{(c)}$. Además, aun si se cumpliera la condición anterior respecto al grupo etario, también habría que considerar el año calendario si el seguimiento se interpretara estrictamente como una trayectoria real en edad y calendario, pues el año t cambiaría al avanzar el tiempo. En ese caso, la fórmula directa con una sola intensidad tendría que sustituirse por un encadenamiento por tramos, usando las intensidades correspondientes a los grupos etarios y años calendario que se vayan cruzando.

Por esta razón, en la aplicación empírica del proyecto se fijará el horizonte en $n = 1$, pues esta elección es la más coherente con la estructura anual de los datos, y hace que el proyecto sea computacionalmente estable y fácilmente interpretable. Una vez hecha esta salvedad, se escribirá simplemente

$$q_{x,t}^{(c)}$$

para referirse a la probabilidad anual de decremento por causa. Es decir,

$$q_{x,t}^{(c)} := {}_1q_{x,t}^{(c)}.$$

Con esta convención, $q_{x,t}^{(c)}$ debe leerse como una probabilidad anual asociada a la celda agregada definida por grupo etario, año calendario, país, sexo y causa. Es decir, representa el riesgo anual estimado de morir por la causa c para el conjunto de vidas expuestas dentro del grupo etario x durante el año t , bajo las intensidades estimadas para esa celda. Por ejemplo, si $x = 30$ representa el grupo 30-34, entonces $q_{30,t}^{(c)}$ representa el riesgo anual estimado del grupo etario 30-34 durante el año t .

Esta cantidad debe entenderse principalmente como una medida del grupo etario, no como una probabilidad exacta para cada edad individual dentro del grupo. Si una persona tuviera una edad exacta dentro de ese intervalo, por ejemplo 31.2 o 32.5, el modelo simplemente la ubicaría dentro del grupo 30-34 y le asociaría la misma intensidad estimada para todo el grupo. Esto ocurre porque los datos no permiten distinguir el riesgo de cada edad exacta por separado. Así, bajo el supuesto de fuerza constante dentro de la celda, edades internas como 30, 31.2, 32.5 o incluso 33.9 quedan representadas por la misma probabilidad grupal $q_{30,t}^{(c)}$, pero no se está haciendo una estimación exacta para cada edad individual.

Con estas salvedades aclaradas, es esencial definir de qué manera se estimará $q_{x,t}^{(c)}$. Para seguir la línea del curso y los métodos allí vistos, se usará tanto un enfoque clásico como uno bayesiano. En este sentido, la comparación no será el fin del proyecto por sí misma, sino un medio para interpretar patrones de variabilidad. Si una celda tiene alta exposición y suficientes defunciones, ambos enfoques deberían producir resultados similares. Si una celda tiene baja exposición, conteos nulos o una causa poco frecuente, el enfoque bayesiano debería producir estimaciones más estabilizadas e intervalos más amplios. El por qué de estos resultados esperados se hará claro conforme se definan los métodos de estimación que se tomará en cada uno de los enfoques.

Enfoque clásico

El primer bloque metodológico será clásico. Para cada celda se modelarán las defunciones por causa como una variable aleatoria de conteo:

$$D_{x,t}^{(c)} \mid \mu_{x,t}^{(c)} \sim \text{Poisson} \left(E_{x,t} \mu_{x,t}^{(c)} \right),$$

Esta formulación se apoya en Manton et al. (1989), argumentan que las defunciones pueden modelarse aproximadamente como una variable Poisson con dichos parámetros. Esto es además coherente con la naturaleza de la distribución Poisson, la cual representa el número de sucesos aleatorios que ocurren en un intervalo de tiempo dado, en este caso dichos sucesos serían las defunciones. Asimismo, $\mu_{x,t}^{(c)}$ se interpreta como la fuerza de mortalidad, es decir, una tasa instantánea de salida del estado vivo por la causa c , asumida constante dentro de la celda anual considerada. Por tanto, al multiplicarla por la exposición $E_{x,t}$, el producto $E_{x,t} \mu_{x,t}^{(c)}$ representa

el número esperado de defunciones por la causa c en dicha celda, lo que justifica que sea el parametro de la Poisson.

Pitacco et al (2009) muestran que, bajo este modelo, la estimación clásica por máxima verosimilitud de la intensidad es

$$\hat{\mu}_{x,t}^{(c)} = \frac{D_{x,t}^{(c)}}{E_{x,t}}.$$

Esta representa cuántas defunciones por la causa c se observan en relación con la población expuesta en esa celda. Luego se construye la fuerza total de salida del estado vivo sumando las intensidades por causa a lo largo de las r causas:

$$\mu_{x,t}^{(\tau)} = \sum_{j=1}^r \mu_{x,t}^{(j)}.$$

La notación (τ) se usa para indicar la mortalidad total por todas las causas consideradas. Esta suma es la parte que hace que el enfoque sea realmente de decrementos múltiples en presencia de causas competitivas, como se mencionó antes, la causa c no se analiza como si fuera la única causa posible, sino en presencia de las demás causas que también pueden producir la muerte dentro del intervalo.

Bajo el supuesto de fuerza constante dentro de la celda anual considerada, la transformación de intensidades a probabilidades de decremento se aplica directamente para el horizonte anual del proyecto. Siguiendo la fórmula de decrementos múltiples bajo fuerza constante presentada por Deshmukh (2012, p. 46), la probabilidad anual de morir por la causa c se expresa como

$$q_{x,t}^{(c)} = \frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right).$$

En consecuencia, la estimación clásica será

$$\hat{q}_{x,t}^{(c)} = \frac{\hat{\mu}_{x,t}^{(c)}}{\hat{\mu}_{x,t}^{(\tau)}} \left(1 - e^{-\hat{\mu}_{x,t}^{(\tau)}} \right).$$

Enfoque bayesiano

El enfoque bayesiano mantiene el mismo modelo de conteo usado en el enfoque clásico, de forma que:

$$D_{x,t}^{(c)} \mid \mu_{x,t}^{(c)} \sim \text{Poisson} \left(E_{x,t} \mu_{x,t}^{(c)} \right).$$

Sin embargo ahora la intensidad de mortalidad por causa se considera una variable aleatoria. La diferencia respecto al enfoque clásico es que ahora $\mu_{x,t}^{(c)}$ no se trata como un parámetro fijo desconocido, sino como una variable aleatoria positiva. Para ello se asigna una distribución Gamma:

$$\mu_{x,t}^{(c)} \sim \text{Gamma} \left(\alpha_p^{(c)}, \beta_p^{(c)} \right), \quad \mathbb{E} \left[\mu_{x,t}^{(c)} \right] = \frac{\alpha_p^{(c)}}{\beta_p^{(c)}}.$$

Se debe recordar que la metodología se aplica dentro de un subconjunto específico país-sexo dados, por ejemplo Costa Rica-hombres, Costa Rica-mujeres, Guatemala-hombres, etc. La única excepción será la notación de los hiperparámetros, donde sí se escribirá el país p . Esto permitirá recordar que $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ se diferenciarán por causa y país, así siendo constantes en las variables de grupo etario x , año calendario t y sexo.

Para formalizar esa idea, para cada sexo, país p y causa c se define

$$\mathcal{J}_p^{(c)} = \{(x, t) : \text{país } p \text{ y causa } c \text{ fijos}\},$$

donde los (x, t) representan todos los pares de índices del grupo etario x en el año calendario t con un sexo dado, correspondientes a esa causa c en ese país p .

Con esas observaciones se estiman los hiperparámetros $\alpha_p^{(c)}$ y $\beta_p^{(c)}$. Es decir, para cada país y causa se usa la información observada en los distintos sexos, grupos etarios y años calendario, pero el resultado final es un único par de hiperparámetros:

$$\alpha_p^{(c)}, \beta_p^{(c)}.$$

Esto se hace así debido a que los hiperparámetros serán estimados mediante un método llamado Empirical Bayes, en donde la idea es que se incorpore una experiencia grupal, de forma que cada celda (x, t) conserva su propia información observada, pero también se beneficia de la experiencia colectiva del país y la causa. Esto es útil porque muchas celdas pueden tener conteos pequeños o incluso nulos.

Por conjugación Poisson-Gamma, una vez estimados los hiperparámetros, se obtiene

$$\mu_{x,t}^{(c)} \mid D_{x,t}^{(c)}, E_{x,t} \sim \text{Gamma} \left(\hat{\alpha}_p^{(c)} + D_{x,t}^{(c)}, \hat{\beta}_p^{(c)} + E_{x,t} \right).$$

Estimación de $\alpha_p^{(c)}$ y $\beta_p^{(c)}$

Los hiperparámetros $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ se estimarán mediante un método llamado Empirical Bayes, inspirados en el enfoque tomado por Zhang et al. (2019). Esto significa que no se fijan subjetivamente, sino que se estiman desde los propios conteos observados.

En este sentido, el modelo bayesiano se puede entender como una jerarquía creciente de 3 niveles:

$$\alpha_p^{(c)}, \beta_p^{(c)} \longrightarrow \mu_{x,t}^{(c)} \longrightarrow D_{x,t}^{(c)}.$$

En el primer nivel, los hiperparámetros $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ describen la experiencia colectiva asociada al país p y a la causa c . En el segundo nivel, cada intensidad específica $\mu_{x,t}^{(c)}$ representa el riesgo latente propio de la celda (x, t) , pero dicha intensidad no se observa directamente. En el tercer nivel se encuentran los conteos observados $D_{x,t}^{(c)}$, que son los datos efectivamente disponibles.

La dificultad es que el nivel intermedio, $\mu_{x,t}^{(c)}$, no se observa directamente, sino que lo observado son las defunciones y exposiciones. Si las fuerzas de mortalidad fueran observadas, se podría estimar fácilmente $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ mediante máxima verosimilitud o algún método similar.

Por lo mencionado anteriormente para estimar los hiperparámetros no se trabaja con una verosimilitud basada en $\mu_{x,t}^{(c)}$ de manera observada, sino con la distribución marginal de los conteos observados. Esto se logra integrando la intensidad latente:

$$P \left(D_{x,t}^{(c)} = d \right) = \int_0^\infty P \left(D_{x,t}^{(c)} = d \mid \mu \right) f \left(\mu \mid \alpha_p^{(c)}, \beta_p^{(c)} \right) d\mu.$$

Este paso elimina el nivel intermedio no observado y deja una relación directa entre los hiperparámetros y los conteos:

$$\alpha_p^{(c)}, \beta_p^{(c)} \longrightarrow D_{x,t}^{(c)}.$$

Como es señalado por Schmitt et al. (2019), al integrar la variable intermedia en nuestra familia conjugada Poisson-Gamma se obtiene una distribución marginal binomial negativa para nivel superior, de forma que:

$$P \left(D_{x,t}^{(c)} = d \right) = \frac{\Gamma \left(\alpha_p^{(c)} + d \right)}{\Gamma \left(\alpha_p^{(c)} \right) d!} \left(\frac{\beta_p^{(c)}}{\beta_p^{(c)} + E_{x,t}} \right)^{\alpha_p^{(c)}} \left(\frac{E_{x,t}}{\beta_p^{(c)} + E_{x,t}} \right)^d.$$

Este procedimiento es precisamente el que permite seguir la lógica Empirical Bayes descrita por Zhang et al. (2019), en donde siguen esta lógica para estimar los hiperparámetros asociados al parámetro original, y concluyen que la mejor forma es mediante máxima verosimilitud, maximizando la log-verosimilitud marginal construida con las celdas (x, t) correspondientes.

Por tanto, para cada país p y causa c , se maximizará la log-verosimilitud marginal, mediante la función `optim()` en R.

$$\ell_p^{(c)}(\alpha, \beta) = \sum_{(x,t) \in \mathcal{J}_p^{(c)}} \left[\log \Gamma(\alpha + D_{x,t}^{(c)}) - \log \Gamma(\alpha) - \log(D_{x,t}^{(c)}!) \right. \\ \left. + \alpha \log \left(\frac{\beta}{\beta + E_{x,t}} \right) + D_{x,t}^{(c)} \log \left(\frac{E_{x,t}}{\beta + E_{x,t}} \right) \right].$$

Así se tiene que, para cada país p y causa c :

$$(\hat{\alpha}_p^{(c)}, \hat{\beta}_p^{(c)}) = \arg \max_{\alpha > 0, \beta > 0} \ell_p^{(c)}(\alpha, \beta).$$

Simulación posterior de $q_{x,t}^{(c)}$

De la explicación brindada en el enfoque clásico y en resonancia con Deshmukh (2012, p. 46) sabemos que:

$$q_{x,t}^{(c)} = \frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right),$$

Sin embargo, como ahora en el enfoque bayesiano cada $\mu_{x,t}^{(j)}$ es una variable aleatoria posterior, entonces la probabilidad de decremento $Q_{x,t}^{(c)}$ también lo es (note que debido a esto ahora se escribirá con una Q mayúscula). Por tanto, al querer estimarla no basta con sustituir directamente las medias posteriores de las intensidades en la fórmula clásica. Esto se debe a que la transformación de intensidades a probabilidades de decremento no es lineal, pues depende de la suma $\mu_{x,t}^{(\tau)} = \sum_{j=1}^r \mu_{x,t}^{(j)}$ dentro de una función exponencial.

Así, bajo función de pérdida cuadrática, el estimador bayesiano de interés es la esperanza posterior de la variable aleatoria $Q_{x,t}^{(c)}$. Debido a que se están usando los r conteos de defunciones (uno por causa) para calcular $\mu_{x,t}^{(\tau)}$, se tiene que dicha esperanza posterior se ve la siguiente manera:

$$\mathbb{E} \left(Q_{x,t}^{(c)} \mid D_{x,t}^{(1)}, \dots, D_{x,t}^{(r)}, E_{x,t} \right) = \mathbb{E} \left[\frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right) \mid D_{x,t}^{(1)}, \dots, D_{x,t}^{(r)}, E_{x,t} \right].$$

Para simplificar la notación, de ahora en adelante se denotará por $\mathcal{D}_{x,t}$ a los conteos de defunciones por causa junto con la exposición correspondiente de la celda x, t . Por tanto, la esperanza anterior se escribirá simplemente como

$$\mathbb{E}[Q_{x,t}^{(c)} \mid \mathcal{D}_{x,t}]$$

Note que $Q_{x,t}^{(c)} = f(\mu_{x,t}^{(1)}, \dots, \mu_{x,t}^{(r)})$ y en general se tiene que

$$\mathbb{E} \left[f \left(\mu_{x,t}^{(1)}, \dots, \mu_{x,t}^{(r)} \right) \mid \mathcal{D}_{x,t} \right] \neq f \left(\mathbb{E} \left[\mu_{x,t}^{(1)} \mid \mathcal{D}_{x,t} \right], \dots, \mathbb{E} \left[\mu_{x,t}^{(r)} \mid \mathcal{D}_{x,t} \right] \right).$$

Por esta razón, no se estimará $Q_{x,t}^{(c)}$ substituyendo directamente las medias posteriores de las intensidades en la fórmula presentada. En su lugar, se deberán hacer simulaciones y aproximar la media posterior de las probabilidades de decrementos mediante Ley de los Grandes Números, esto se hará de la siguiente manera:

Para cada celda (x, t) y para cada simulación $s = 1, \dots, S$, se generan intensidades posteriores por causa:

$$\mu_{x,t}^{(j,s)} \sim \text{Gamma} \left(\hat{\alpha}_p^{(j)} + D_{x,t}^{(j)}, \hat{\beta}_p^{(j)} + E_{x,t} \right), \quad j = 1, \dots, r.$$

Luego, para esa misma simulación, se calcula la intensidad total simulada:

$$\mu_{x,t}^{(\tau,s)} = \sum_{j=1}^r \mu_{x,t}^{(j,s)}.$$

Con estas intensidades simuladas se obtiene una realización posterior de la probabilidad de decremento por causa c :

$$q_{x,t}^{(c,s)} = \frac{\mu_{x,t}^{(c,s)}}{\mu_{x,t}^{(\tau,s)}} \left(1 - e^{-\mu_{x,t}^{(\tau,s)}} \right).$$

Después de S simulaciones, para cada causa c se obtiene una muestra de la forma

$$q_{x,t}^{(c,1)}, \dots, q_{x,t}^{(c,S)}.$$

Para S grande se tiene que el estimador bayesiano de $Q_{x,t}^{(c)}$ de dicha causa c se aproxima entonces como la media muestral de dicho conjunto:

$$q_{x,t}^{(c)*} = \frac{1}{S} \sum_{s=1}^S q_{x,t}^{(c,s)} \approx \mathbb{E} \left(Q_{x,t}^{(c)} \mid \mathcal{D}_{x,t} \right).$$

Esta aproximación se justifica por la Ley de los Grandes Números.