

Bitácora 3

Universidad de Costa Rica

Escuela de Matemática

Departamento de Matemática y Ciencias Actuariales

Proyecto de Investigación

Análisis del cambio de la probabilidad de decremento ${}_nq_x^{(c)}$ para grupos etarios por causas de muerte de acuerdo a la clasificación ICD-10 en países de Centroamérica [2015, 2018].

Integrantes

Sebastián Miranda Ramírez C4H274

Benjamín Gutiérrez Padua C4F813

Kevin David Calderón Martínez C4D511

Gabriel de Jesús Chaves Esquivel C4E273

Profesor

Maikol Solís Chacón

2026

Bitácora 3

1. Parte de Planificación

1.2.1. Formulación metodológica del proyecto

La metodología del proyecto se construye alrededor de estimar la probabilidad actuarial de decremento por causa,

$${}_nq_{x,t}^{(c)} = P(T_{x,t} \leq n, J = c),$$

donde x representa el del grupo etario de cada persona y t el año calendario en el cual se encuentran,

$$x \in \{0, 1, 2, 3, 4, 5-9, 10-14, \dots, 90-94, 95+\}, \quad t \in \{2015, 2016, 2017, 2018\}$$

y c una categoría de causa de muerte según la ICD-10, de acuerdo con la clasificación definida en bitácoras anteriores. En particular, cuando el grupo etario se denote por su edad inicial, x también puede leerse como el extremo inferior del intervalo. Por ejemplo, para el grupo 30-34 se puede escribir $x = 30$ y asociar el intervalo $I_x = [30, 35)$, esta convención se usará al escribir las diversas fórmulas a estimar.

La variable aleatoria $T_{x,t}$ representa el tiempo futuro de vida de una persona perteneciente al grupo etario x durante el año calendario t y J es una variable aleatoria que indica la causa del decremento. Con esta convención, $q_{x,t}^{(c)}$ debe leerse como la probabilidad de morir por la causa c para una vida perteneciente al grupo etario x durante el año calendario t , bajo las intensidades estimadas para esa celda. Por ejemplo, si $x = 30-34$, entonces $q_{30-34,t}^{(c)}$ no se interpreta como la probabilidad exacta de una persona de edad puntual 30, 33.9 o 34.7, sino como el riesgo anual asociado al grupo etario completo 30-34 durante el año t . Asimismo se considera que para que alguien muera por la causa c primero debe no haber muerto por las otras $c - 1$ causas, de manera que estas se consideran “causas competidoras” e influyen en el cálculo de las diferentes probabilidades. Bowers et al. (1997) y Deshmukh (2012) presentan este tratamiento para las probabilidades de decremento.

Aunque el objeto de estudio también depende del país y del sexo, estas dimensiones se mantienen en el cálculo, pero se omiten de la expresión para no sobrecargar la notación, en el momento de presentación de resultados se hará explícito el sexo y el país al que se esté refiriendo cada aseveración. De forma más general, la probabilidad podría escribirse como ${}_nq_{x,t,p,s}^{(c)}$, donde p representa el país y s el sexo.

Con respecto al sistema de clasificación de las causas de defunción: Existe una estandarización aún más general para la clasificación de enfermedades utilizando números romanos, la cual

fue propuesta por la misma WHO, para agrupar de manera más amplia la causa de muerte en el cálculo de las tablas de vida de decrementos múltiples. Para efectos de este trabajo, se utilizará este estándar para un mejor manejo de datos. A continuación una tabla que explica el estándar:

Tabla 1: *Explicación de la lista de tabulación de mortalidad de la ICD-10. Obtenido de: World Health Organization (WHO)*

Grupo	ICD-10	Causa
I	A00-B99, R75	Enfermedades infecciosas y parasitarias
II	C00-D48	Tumores
III	D50-D89	Enfermedades de la sangre y de los órganos hematopoyéticos, y ciertos trastornos que afectan al mecanismo de la inmunidad
IV	E00-E90	Enfermedades endocrinas, nutricionales y metabólicas
V-VIII	F00-H95	Trastornos mentales y del comportamiento (V) y Enfermedades del sistema nervioso y de los órganos de los sentidos (VI-VIII)
IX	I00-I99	Enfermedades del sistema circulatorio
X	J00-J99	Enfermedades del sistema respiratorio
XI	K00-K93	Enfermedades del sistema digestivo
XII	L00-L99	Enfermedades de la piel y del tejido subcutáneo
XIII	M00-M99	Enfermedades del sistema osteomuscular y del tejido conjuntivo
XIV	N00-N99	Enfermedades del sistema genitourinario
XV	O00-O99	Embarazo, parto y puerperio
XVI	P00-P96	Afecciones originadas en el periodo perinatal
XVII	Q00-Q99	Malformaciones congénitas, deformidades y anomalías cromosómicas
XVIII	R00-R74, R76-R99, U00-U99	Síntomas, signos y hallazgos anormales clínicos y de laboratorio, no clasificados en otra parte.
XX	V01-Y89	Causas externas de mortalidad

Para la estimación de estas causas se deberá de recurrir a los datos disponibles en la WHO Mortality Database, los cuales se presentan de manera agregada, por tanto la unidad de análisis será una celda definida por país y sexo dados, así como año calendario t , grupo etario x y causa de muerte c . Para cada celda se tendrá un conteo de defunciones,

$$D_{x,t}^{(c)},$$

obtenido de la WHO Mortality Database, y una exposición en años-persona,

$$E_{x,t},$$

aproximada mediante la población a mitad de año correspondiente al mismo país, sexo, año calendario y grupo etario, obtenida de World Population Prospects 2024. Esta aproximación es metodológicamente razonable en este contexto, pues la población a mitad de año suele utilizarse como aproximación de la exposición al riesgo cuando se trabaja con datos agregados anuales; Pitacco et al. (2009) discuten esta interpretación de la exposición en modelos de mortalidad.

Antes de pasar a los enfoques de estimación, es necesario aclarar con mayor precisión los supuestos bajo los cuales se interpretará el objeto actuarial del proyecto. En este sentido, la notación actuarial general ${}_nq_{x,t}^{(c)}$ es útil para introducir la idea de probabilidad de decremento por causa, y además es cercana a la notación estándar utilizada en trabajos sobre probabilidades de decrementos múltiples. En una formulación actuarial más general, para trabajar con ${}_nq_{x',t'}^{(c)}$ se puede interpretar x' como una edad exacta y t' como un momento exacto del calendario. Sin embargo, en dichos trabajos se suele contar con maneras precisas de estimar las probabilidades ${}_nq_{x',t'}^{(c)}$, para al menos todos los x', t' enteros, de manera que mediante supuestos como fuerza de mortalidad constante en cada celda $[x', x' + 1)$ y $[t', t' + 1)$ se pueden estimar toda la familia de probabilidades ${}_nq_{x',t'}^{(c)}$, para x', t', n reales.

Sin embargo, en este trabajo no se cuenta con datos para todas las edades exactas x' ni para todos los momentos calendario t' , debido a la naturaleza agregada de la WHO Mortality Database. Los datos disponibles están agrupados por grupo etario y año calendario, a excepción de los primeros años de vida, donde sí aparecen de manera más desagregada. Por esta razón, en nuestro trabajo x no representa una edad exacta individual, sino que indexa el grupo etario al que pertenece la persona.

Por tanto, el supuesto de fuerza constante no se hará solamente sobre una celda del estilo $[x', x' + 1)$ y $[t', t' + 1)$ para edades exactas, sino sobre todo el intervalo de edad asociado al grupo etario durante un año calendario. Así, para un país y sexo fijados, si I_x representa el grupo etario asociado a x , y si t representa el año calendario, se asumirá que la fuerza de mortalidad por causa es constante dentro de la celda formada por grupo etario y año calendario. Es decir, si

$$I_x = [a_x, b_x),$$

entonces se supondrá que

$$\mu_{y,z}^{(c)} = \mu_{x,t}^{(c)}$$

para edades exactas $y \in I_x$ y momentos calendario $z \in [t, t + 1)$, donde $\mu_{x,t}^{(c)}$ representa la intensidad o tasa central de mortalidad por la causa c para la celda definida por grupo etario x y año calendario t .

En el caso particular de grupos quinquenales, si el grupo se denota por su edad inicial y se escribe $I_x = [x, x + 5)$, el supuesto anterior equivale a asumir que

$$\mu_{x+\xi_1, t+\xi_2}^{(c)} = \mu_{x,t}^{(c)}, \quad 0 \leq \xi_1 < 5, \quad 0 \leq \xi_2 < 1.$$

En otras palabras, $\mu_{x,t}^{(c)}$ no representa una intensidad propia de una edad exacta como 33.9, sino la intensidad estimada para todo el grupo etario x durante el año t . Por ejemplo, si $x = 30$ representa el grupo 30-34, entonces $\mu_{30,t}^{(c)}$ representa una única intensidad asociada al intervalo $I_{30} = [30, 35)$ durante el año calendario t .

Esta aclaración es importante porque ${}_nq_{x,t}^{(c)}$, para un horizonte general n , solo puede usarse directamente con una única intensidad de muerte cuando el intervalo considerado permanece dentro de la celda donde esa intensidad fue asumida constante. Si una persona tuviera una edad exacta $y \in I_x$ y se quisiera seguir durante n años usando solamente $\mu_{x,t}^{(c)}$, tendría que cumplirse al menos que

$$y + n \leq b_x.$$

Si esta condición no se cumple, la persona saldría del grupo etario I_x y entraría en otro grupo, por lo que ya no sería correcto usar únicamente la intensidad $\mu_{x,t}^{(c)}$. Además, aun si se cumpliera la condición anterior respecto al grupo etario, también habría que considerar el año calendario si el seguimiento se interpretara estrictamente como una trayectoria real en edad y calendario, pues el año t cambiaría al avanzar el tiempo. En ese caso, la fórmula directa con una sola intensidad tendría que sustituirse por un encadenamiento por tramos, usando las intensidades correspondientes a los grupos etarios y años calendario que se vayan cruzando.

Por esta razón, en la aplicación empírica del proyecto se fijará el horizonte en $n = 1$, pues esta elección es la más coherente con la estructura anual de los datos, y hace que el proyecto sea computacionalmente estable y fácilmente interpretable. Una vez hecha esta salvedad, se escribirá simplemente

$$q_{x,t}^{(c)}$$

para referirse a la probabilidad anual de decremento por causa. Es decir,

$$q_{x,t}^{(c)} := {}_1q_{x,t}^{(c)}.$$

Con esta convención, $q_{x,t}^{(c)}$ debe leerse como una probabilidad anual asociada a la celda agregada definida por grupo etario, año calendario, país, sexo y causa. Es decir, representa el riesgo anual estimado de morir por la causa c para el conjunto de vidas expuestas dentro del grupo etario x durante el año t , bajo las intensidades estimadas para esa celda. Por ejemplo, si $x = 30$ representa el grupo 30-34, entonces $q_{30,t}^{(c)}$ representa el riesgo anual estimado del grupo etario 30-34 durante el año t .

Esta cantidad debe entenderse principalmente como una medida del grupo etario, no como una probabilidad exacta para cada edad individual dentro del grupo. Si una persona tuviera una edad exacta dentro de ese intervalo, por ejemplo 31.2 o 32.5, el modelo simplemente la ubicaría dentro del grupo 30-34 y le asociaría la misma intensidad estimada para todo el grupo. Esto ocurre porque los datos no permiten distinguir el riesgo de cada edad exacta por separado. Así, bajo el supuesto de fuerza constante dentro de la celda, edades internas como 30, 31.2, 32.5 o incluso 33.9 quedan representadas por la misma probabilidad grupal $q_{30,t}^{(c)}$, pero no se está haciendo una estimación exacta para cada edad individual.

Con estas salvedades aclaradas, es esencial definir de qué manera se estimará $q_{x,t}^{(c)}$. Para seguir la línea del curso y los métodos allí vistos, se usará tanto un enfoque clásico como uno bayesiano. En este sentido, la comparación no será el fin del proyecto por sí misma, sino un medio para interpretar patrones de variabilidad. Si una celda tiene alta exposición y suficientes defunciones, ambos enfoques deberían producir resultados similares. Si una celda tiene baja exposición, conteos nulos o una causa poco frecuente, el enfoque bayesiano debería producir estimaciones más estabilizadas e intervalos más amplios. El por qué de estos resultados esperados se hará claro conforme se definan los métodos de estimación que se tomará en cada uno de los enfoques.

Enfoque clásico

El primer bloque metodológico será clásico. Para cada celda se modelarán las defunciones por causa como una variable aleatoria de conteo:

$$D_{x,t}^{(c)} \mid \mu_{x,t}^{(c)} \sim \text{Poisson} \left(E_{x,t} \mu_{x,t}^{(c)} \right),$$

Esta formulación se apoya en Manton et al. (1989), argumentan que las defunciones pueden modelarse aproximadamente como una variable Poisson con dichos parámetros. Esto es además coherente con la naturaleza de la distribución Poisson, la cual representa el número de sucesos aleatorios que ocurren en un intervalo de tiempo dado, en este caso dichos sucesos serían las defunciones. Asimismo, $\mu_{x,t}^{(c)}$ se interpreta como la fuerza de mortalidad, es decir, una tasa instantánea de salida del estado vivo por la causa c , asumida constante dentro de la celda anual considerada. Por tanto, al multiplicarla por la exposición $E_{x,t}$, el producto $E_{x,t} \mu_{x,t}^{(c)}$ representa el número esperado de defunciones por la causa c en dicha celda, lo que justifica que sea el parámetro de la Poisson.

Pitacco et al (2009) muestran que, bajo este modelo, la estimación clásica por máxima verosimilitud de la intensidad es

$$\hat{\mu}_{x,t}^{(c)} = \frac{D_{x,t}^{(c)}}{E_{x,t}}.$$

Esta representa cuántas defunciones por la causa c se observan en relación con la población expuesta en esa celda. Luego se construye la fuerza total de salida del estado vivo sumando las intensidades por causa a lo largo de las r causas:

$$\mu_{x,t}^{(\tau)} = \sum_{j=1}^r \mu_{x,t}^{(j)}.$$

La notación (τ) se usa para indicar la mortalidad total por todas las causas consideradas. Esta suma es la parte que hace que el enfoque sea realmente de decrementos múltiples en presencia de causas competitivas, como se mencionó antes, la causa c no se analiza como si fuera la única causa posible, sino en presencia de las demás causas que también pueden producir la muerte dentro del intervalo.

Bajo el supuesto de fuerza constante dentro de la celda anual considerada, la transformación de intensidades a probabilidades de decremento se aplica directamente para el horizonte anual del proyecto. Siguiendo la fórmula de decrementos múltiples bajo fuerza constante presentada por Deshmukh (2012, p. 46), la probabilidad anual de morir por la causa c se expresa como

$$q_{x,t}^{(c)} = \frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right).$$

En consecuencia, la estimación clásica será

$$\hat{q}_{x,t}^{(c)} = \frac{\hat{\mu}_{x,t}^{(c)}}{\hat{\mu}_{x,t}^{(\tau)}} \left(1 - e^{-\hat{\mu}_{x,t}^{(\tau)}} \right).$$

Análisis de las probabilidades de decremento desde el enfoque clásico

Una vez estimadas las probabilidades clásicas de decremento por causa, se construyen tres análisis derivados: La probabilidad de decremento por causa, la composición causal condicionada al fallecimiento y la concentración causal. Estos análisis constituyen un enfoque probabilístico que compara entre sí las causas de decremento. Su propósito es responder la pregunta planteada inicialmente; cómo varía la probabilidad de decremento por causa según grupo etario, país, sexo y año calendario.

Inicialmente, el primer análisis gráfico corresponde a la probabilidad de decremento por causa,

$$\hat{q}_{x,t}^{(c)}.$$

Esta cantidad mide la magnitud real del riesgo de decremento por causa. En la presentación gráfica se plantea utilizar

$$100\hat{q}_{x,t}^{(c)},$$

de manera que el eje vertical pueda interpretarse como porcentaje. Este análisis permite comparar, para cada país y sexo, cómo cambia la probabilidad anual de fallecer por una causa específica entre 2015 y 2018 a lo largo de los grupos etarios.

El segundo análisis corresponde a la composición causal condicionada al fallecimiento. Para una celda fija, la probabilidad total de fallecimiento por cualquier causa es

$$\hat{q}_{x,t}^{(\tau)} = \sum_{j=1}^r \hat{q}_{x,t}^{(j)}.$$

A partir de esta cantidad se define la composición causal condicionada al fallecimiento. Para justificarla, considérese, para una celda fija, el evento

$$A_c = \{T_{x,t} \leq 1, J = c\},$$

correspondiente a fallecer durante un horizonte anual por la causa c , y el evento

$$B = \{T_{x,t} \leq 1\},$$

correspondiente a fallecer durante ese mismo horizonte anual por cualquier causa. Por definición,

$$P(A_c) = \hat{q}_{x,t}^{(c)}.$$

Como las causas son mutuamente excluyentes y exhaustivas, el evento B es la unión disjunta de los eventos $A_1, \dots, A_r$. Por tanto,

$$P(B) = \sum_{j=1}^r P(A_j) = \sum_{j=1}^r \hat{q}_{x,t}^{(j)} = \hat{q}_{x,t}^{(\tau)}.$$

Además, como $A_c \subseteq B$, se tiene $A_c \cap B = A_c$. Así, mediante la definición de probabilidad condicional considere

$$\pi_{x,t}^{(c)} := P(J = c \mid T_{x,t} \leq 1) = \frac{P(A_c \cap B)}{P(B)} = \frac{q_{x,t}^{(c)}}{\sum_{j=1}^r q_{x,t}^{(j)}}.$$

Al sustituir las probabilidades desconocidas por sus estimaciones, se obtiene

$$\hat{\pi}_{x,t}^{(c)} = \frac{\hat{q}_{x,t}^{(c)}}{\sum_{j=1}^r \hat{q}_{x,t}^{(j)}}.$$

La condición $T_{x,t} \leq 1$ modifica el conjunto de referencia sobre el cual se calcula la probabilidad. Sin condicionar, $q_{x,t}^{(c)}$ considera a todas las vidas pertenecientes a la celda y mide la probabilidad de que una de ellas fallezca por la causa c durante el horizonte anual. En cambio, al condicionar a que $T_{x,t} \leq 1$, se excluyen del conjunto de referencia todas las vidas que sobreviven ese año y se consideran únicamente aquellas que fallecen.

Por tanto,

$$\pi_{x,t}^{(c)} = P(J = c \mid T_{x,t} \leq 1)$$

responde a la siguiente pregunta: dado que una vida perteneciente a la celda (x, t) fallece durante el próximo año, ¿cuál es la probabilidad de que ese fallecimiento sea atribuible a la causa c ?

Así, $\hat{q}_{x,t}^{(c)}$ mide un riesgo absoluto respecto de todas las vidas de la celda, mientras que $\hat{\pi}_{x,t}^{(c)}$ mide una composición causal respecto únicamente de las vidas que fallecen. Por ejemplo, si la probabilidad anual total de fallecimiento es 0.02 y la probabilidad de fallecer por la causa c es 0.006, entonces

$$\hat{\pi}_{x,t}^{(c)} = \frac{0.006}{0.02} = 0.30.$$

Esto no significa que el 30% de las vidas de la celda fallezca por la causa c , sino que, entre los fallecimientos ocurridos durante el horizonte anual, el 30% se atribuye probabilísticamente a dicha causa.

Asimismo es importante notar que para una celda fija, las cantidades estimadas $\hat{\pi}_{x,t}^{(c)}$ forman una distribución de probabilidad sobre las causas, ya que

$$\sum_{c=1}^r \hat{\pi}_{x,t}^{(c)} = \sum_{c=1}^r \frac{\hat{q}_{x,t}^{(c)}}{\sum_{j=1}^r \hat{q}_{x,t}^{(j)}} = 1.$$

Porque, una vez condicionado a que ocurrió un fallecimiento, la persona necesariamente tuvo que morir por una de las r causas consideradas. Por tanto, las probabilidades condicionadas distribuyen la totalidad de la probabilidad entre las causas.

Esta propiedad justifica el uso de gráficos de composición condicionada, similares en espíritu a los análisis de distribución de causas de muerte por grupo de edad, utilizados por Goerlich (2012, p.36). Sin embargo, para mantener la legibilidad, se propone mostrar únicamente algunas causas seleccionadas. En estos casos, el denominador de $\hat{\pi}_{x,t}^{(c)}$ continuará incluyendo la suma de las probabilidades de decremento correspondientes a todas las causas, aunque solo se visualicen algunas. Por esta razón, cuando se presenten únicamente causas seleccionadas, las barras visibles no necesariamente sumarían 100%.

El tercer análisis resume la concentración de la composición causal. Dado que $\hat{\pi}_{x,t}^{(c)}$ define una distribución de probabilidad sobre las causas de muerte, se calcula el índice

$$H_{x,t} = \sum_{c=1}^r \left(\hat{\pi}_{x,t}^{(c)} \right)^2 = \sum_{c=1}^r \left(\frac{\hat{q}_{x,t}^{(c)}}{\sum_{j=1}^r \hat{q}_{x,t}^{(j)}} \right)^2.$$

Este índice es una medida tipo Herfindahl-Simpson aplicada a la composición causal. Su valor se encuentra entre $1/r$ y 1. Valores altos indican que la mortalidad de la celda está concentrada en pocas causas; valores bajos indican que la mortalidad está más distribuida entre varias causas [Simpson1949; Herfindahl1950; Hirschman1964].

La interpretación probabilística de $H_{x,t}$ es directa. Si se seleccionan dos fallecimientos de manera independiente dentro de la misma celda, y si la probabilidad de que un fallecimiento corresponda a la causa c es $\hat{\pi}_{x,t}^{(c)}$, entonces la probabilidad de que ambos fallecimientos correspondan a la misma causa es

$$\sum_{c=1}^r \hat{\pi}_{x,t}^{(c)} \hat{\pi}_{x,t}^{(c)} = \sum_{c=1}^r \left(\hat{\pi}_{x,t}^{(c)} \right)^2 = H_{x,t}.$$

Por tanto, $H_{x,t}$ no se introduce únicamente como un indicador descriptivo, sino como una función de la distribución condicional de causas. En el contexto del proyecto, permite identificar si la mortalidad de un grupo etario está dominada por una causa particular o si se reparte entre múltiples categorías.

En conjunto, los tres análisis cumplen funciones complementarias. La probabilidad absoluta $\hat{q}_{x,t}^{(c)}$ permite analizar la magnitud del decremento por causa. La composición condicionada $\hat{\pi}_{x,t}^{(c)}$ permite estudiar la estructura causal de las muertes dentro de cada grupo etario. Finalmente,

el índice $H_{x,t}$ resume el grado de concentración de dicha estructura causal. Así, los gráficos utilizados no se plantean como visualizaciones aisladas, sino como representaciones de cantidades probabilísticas derivadas del modelo clásico de decrementos múltiples.

Para efectos de visualización, las causas principales se seleccionan por país. Se incluye la categoría de causas externas de mortalidad debido a su relevancia en edades jóvenes y adultas, y se completan las restantes con las causas de mayor probabilidad promedio de decremento dentro del país. Además, las afecciones originadas en el periodo perinatal se analizan por separado, dado que presentan un perfil etario estructuralmente distinto, concentrado en edades iniciales. Esta selección afecta únicamente la presentación gráfica; los denominadores utilizados en $\hat{q}_{x,t}^{(\tau)}$, $\hat{\pi}_{x,t}^{(c)}$ y $H_{x,t}$ se calculan con todas las causas disponibles en cada celda.

Enfoque bayesiano

El enfoque bayesiano mantiene el mismo modelo de conteo usado en el enfoque clásico, de forma que:

$$D_{x,t}^{(c)} \mid \mu_{x,t}^{(c)} \sim \text{Poisson} \left(E_{x,t} \mu_{x,t}^{(c)} \right).$$

Sin embargo ahora la intensidad de mortalidad por causa se considera una variable aleatoria. La diferencia respecto al enfoque clásico es que ahora $\mu_{x,t}^{(c)}$ no se trata como un parámetro fijo desconocido, sino como una variable aleatoria positiva. Para ello se asigna una distribución Gamma:

$$\mu_{x,t}^{(c)} \sim \text{Gamma} \left(\alpha_p^{(c)}, \beta_p^{(c)} \right), \quad \mathbb{E} \left[\mu_{x,t}^{(c)} \right] = \frac{\alpha_p^{(c)}}{\beta_p^{(c)}}.$$

Se debe recordar que, aunque en buena parte de la metodología se omiten el país y el sexo de la notación para evitar sobrecargarla, la estimación se realiza utilizando celdas definidas por país, sexo, grupo etario, año calendario y causa. En el caso de los hiperparámetros sí se mantendrá explícito el país p , ya que se estimará un par distinto para cada combinación de país y causa:

$$\alpha_p^{(c)}, \beta_p^{(c)}.$$

Estos hiperparámetros serán comunes para los distintos sexos, grupos etarios y años calendario incluidos en la experiencia colectiva del país p y la causa c . Es decir, para cada país y causa se utilizará la información observada en ambos sexos, los distintos grupos etarios y los años 2015 a 2018, pero el resultado será un único par de hiperparámetros.

Para formalizar esta idea, se define

$$\mathcal{J}_p^{(c)} = \{(s, x, t) : \text{país } p \text{ y causa } c \text{ fijos}\},$$

donde s representa el sexo, x el grupo etario y t el año calendario. Por tanto, $\mathcal{J}_p^{(c)}$ contiene las celdas cuya experiencia se utilizará para estimar los hiperparámetros correspondientes al país p y la causa c .

Para la mayoría de las causas, el conjunto $\mathcal{J}_p^{(c)}$ incluirá todas las combinaciones disponibles de sexo, grupo etario y año calendario. Sin embargo, antes de realizar la estimación es necesario distinguir entre ceros observacionales y ceros estructurales.

Un cero observacional corresponde a una celda en la cual la muerte por la causa c es posible, pero no se registraron defunciones durante el año analizado. Estas celdas deben mantenerse en la estimación, ya que aportan información sobre la intensidad de mortalidad.

En cambio, un cero estructural corresponde a una combinación de sexo o grupo etario para la cual la causa no resulta aplicable. Estas celdas no deben interpretarse como observaciones de una intensidad pequeña, sino como casos que se encuentran fuera del conjunto de riesgo correspondiente a la causa.

En particular, para la causa XV, correspondiente a embarazo, parto y puerperio, se define

$$\mathcal{J}_p^{(XV)} = \left\{ (\text{Mujer}, x, t) : \begin{array}{l} x \in \{10-14, 15-19, \dots, 50-54\}, \\ t \in \{2015, 2016, 2017, 2018\} \end{array} \right\}.$$

Por tanto, para esta causa no se utilizarán en la estimación de los hiperparámetros las celdas correspondientes a hombres ni los grupos etarios situados fuera de dicho intervalo. No obstante, los conteos iguales a cero que aparezcan dentro de las celdas femeninas incluidas sí permanecerán en la estimación.

Para la causa XVI, afecciones originadas en el periodo perinatal, se define

$$\mathcal{J}_p^{(XVI)} := \{(s, 0-4, t) : s \in \{\text{Hombre}, \text{Mujer}\}, \quad t \in \{2015, 2016, 2017, 2018\}\}.$$

En este caso, la estimación utilizará solamente las celdas correspondientes al grupo etario 0-4, para ambos sexos y todos los años disponibles. Los conteos nulos observados dentro de estas celdas también se conservarán.

Así, las restricciones anteriores no implican eliminar de manera general las observaciones para las cuales

$$D_{x,t,s}^{(c)} = 0.$$

Únicamente se excluyen las celdas que se encuentran fuera del dominio de aplicación de la causa.

Esto permite mantener la idea de experiencia colectiva propia del enfoque Empirical Bayes. Cada celda conserva su información observada, pero la estimación de su intensidad se beneficia de la experiencia conjunta del país y la causa. Esta característica resulta especialmente útil cuando existen celdas con poca exposición, conteos pequeños o conteos nulos.

Estimación de $\alpha_p^{(c)}$ y $\beta_p^{(c)}$

Los hiperparámetros $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ se estimarán mediante un enfoque Empirical Bayes, inspirado en el procedimiento presentado por Zhang et al. (2019). Esto significa que no se fijarán subjetivamente, sino que se estimarán a partir de los conteos observados pertenecientes al conjunto $\mathcal{J}_p^{(c)}$.

El modelo bayesiano puede representarse mediante la jerarquía

$$\alpha_p^{(c)}, \beta_p^{(c)} \longrightarrow \mu_{x,t,s}^{(c)} \longrightarrow D_{x,t,s}^{(c)}.$$

En el primer nivel, los hiperparámetros $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ describen la experiencia colectiva asociada al país p y a la causa c . En el segundo nivel, cada intensidad $\mu_{x,t,s}^{(c)}$ representa el riesgo latente propio de una celda definida por sexo, grupo etario y año calendario. Finalmente, en el tercer nivel se encuentran los conteos observados $D_{x,t,s}^{(c)}$.

Para cada celda aplicable se mantiene el modelo

$$D_{x,t,s}^{(c)} \mid \mu_{x,t,s}^{(c)} \sim \text{Poisson} \left(E_{x,t,s} \mu_{x,t,s}^{(c)} \right),$$

junto con la distribución previa

$$\mu_{x,t,s}^{(c)} \sim \text{Gamma} \left(\alpha_p^{(c)}, \beta_p^{(c)} \right),$$

donde $\beta_p^{(c)}$ se parametriza como tasa. Por tanto,

$$\mathbb{E} \left[\mu_{x,t,s}^{(c)} \right] = \frac{\alpha_p^{(c)}}{\beta_p^{(c)}}.$$

La dificultad es que las intensidades $\mu_{x,t,s}^{(c)}$ no se observan directamente. Los datos disponibles son las defunciones $D_{x,t,s}^{(c)}$ y las exposiciones $E_{x,t,s}$. Por ello, los hiperparámetros no se estimarán utilizando una muestra observada de intensidades, sino mediante la distribución marginal de los conteos.

Esta distribución se obtiene integrando la intensidad latente:

$$P\left(D_{x,t,s}^{(c)} = d\right) = \int_0^\infty P\left(D_{x,t,s}^{(c)} = d \mid \mu\right) f\left(\mu \mid \alpha_p^{(c)}, \beta_p^{(c)}\right) d\mu.$$

Este procedimiento elimina el nivel intermedio no observado y produce una relación directa entre los hiperparámetros y los conteos:

$$\alpha_p^{(c)}, \beta_p^{(c)} \longrightarrow D_{x,t,s}^{(c)}.$$

Como señalan Schmitt et al. (2019), al integrar la intensidad en el modelo conjugado Poisson–Gamma se obtiene una distribución marginal binomial negativa:

$$P\left(D_{x,t,s}^{(c)} = d\right) = \frac{\Gamma\left(\alpha_p^{(c)} + d\right)}{\Gamma\left(\alpha_p^{(c)}\right) d!} \left(\frac{\beta_p^{(c)}}{\beta_p^{(c)} + E_{x,t,s}}\right)^{\alpha_p^{(c)}} \left(\frac{E_{x,t,s}}{\beta_p^{(c)} + E_{x,t,s}}\right)^d.$$

Siguiendo la lógica Empirical Bayes descrita por Zhang et al. (2019), los hiperparámetros se estimarán mediante máxima verosimilitud marginal. Para cada país p y causa c , se construye la log-verosimilitud

$$\begin{aligned} \ell_p^{(c)}(\alpha, \beta) = \sum_{(s,x,t) \in \mathcal{I}_p^{(c)}} & \left[\log \Gamma\left(\alpha + D_{x,t,s}^{(c)}\right) - \log \Gamma(\alpha) - \log\left(D_{x,t,s}^{(c)}!\right) \right. \\ & \left. + \alpha \log\left(\frac{\beta}{\beta + E_{x,t,s}}\right) + D_{x,t,s}^{(c)} \log\left(\frac{E_{x,t,s}}{\beta + E_{x,t,s}}\right) \right]. \end{aligned}$$

Por tanto, para cada país p y causa c , los estimadores Empirical Bayes se definen como

$$\left(\hat{\alpha}_p^{(c)}, \hat{\beta}_p^{(c)}\right) = \arg \max_{\alpha > 0, \beta > 0} \ell_p^{(c)}(\alpha, \beta).$$

La maximización se realizará numéricamente mediante la función `optim()` de R. Para garantizar que los parámetros permanezcan positivos, la optimización se realizará sobre $\log(\alpha)$ y $\log(\beta)$, recuperando posteriormente los valores de α y β mediante la función exponencial. Esta transformación no modifica el criterio de máxima verosimilitud, sino que facilita la búsqueda numérica respetando las restricciones

$$\alpha > 0, \quad \beta > 0.$$

Una vez estimados los hiperparámetros, para cada celda perteneciente a $\mathcal{J}_p^{(c)}$ se obtiene por conjugación Poisson–Gamma

$$\mu_{x,t,s}^{(c)} \mid D_{x,t,s}^{(c)}, E_{x,t,s} \sim \text{Gamma} \left(\hat{\alpha}_p^{(c)} + D_{x,t,s}^{(c)}, \hat{\beta}_p^{(c)} + E_{x,t,s} \right).$$

Para las celdas situadas fuera de $\mathcal{J}_p^{(c)}$ no se generará una intensidad mediante la distribución Gamma posterior. En la implementación, su contribución a la intensidad total de la celda se fijará en cero y se conservará un indicador que señale que la causa no fue considerada aplicable dentro del dominio definido para el proyecto.

Este valor nulo no debe interpretarse necesariamente como una afirmación general de imposibilidad biológica, sino como una restricción del dominio de modelación adoptado según el sexo, la agrupación etaria y el soporte observado en los datos. La excepción más clara corresponde a la causa XV en hombres, para la cual el cero sí se considera estructural.

En cambio, las celdas pertenecientes a $\mathcal{J}_p^{(c)}$ permanecerán en la estimación incluso cuando $D_{x,t,s}^{(c)} = 0$. En esos casos, la intensidad posterior no se fija en cero, sino que se obtiene mediante

$$\mu_{x,t,s}^{(c)} \mid D_{x,t,s}^{(c)} = 0 \sim \text{Gamma} \left(\hat{\alpha}_p^{(c)} + 0, \hat{\beta}_p^{(c)} + E_{x,t,s} \right).$$

Simulación posterior de $q_{x,t}^{(c)}$

De la explicación brindada en el enfoque clásico y en resonancia con Deshmukh (2012, p. 46) sabemos que:

$$q_{x,t}^{(c)} = \frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right),$$

Sin embargo, como ahora en el enfoque bayesiano cada $\mu_{x,t}^{(j)}$ es una variable aleatoria posterior, entonces la probabilidad de decremento $Q_{x,t}^{(c)}$ también lo es (note que debido a esto ahora se escribirá con una Q mayúscula). Por tanto, al querer estimarla no basta con sustituir directamente las medias posteriores de las intensidades en la fórmula clásica. Esto se debe a que la transformación de intensidades a probabilidades de decremento no es lineal, pues depende de la suma $\mu_{x,t}^{(\tau)} = \sum_{j=1}^r \mu_{x,t}^{(j)}$ dentro de una función exponencial.

Así, bajo función de pérdida cuadrática, el estimador bayesiano de interés es la esperanza posterior de la variable aleatoria $Q_{x,t}^{(c)}$. Debido a que se están usando los r conteos de defunciones (uno por causa) para calcular $\mu_{x,t}^{(\tau)}$, se tiene que dicha esperanza posterior se ve la siguiente manera:

$$\mathbb{E} \left(Q_{x,t}^{(c)} \mid D_{x,t}^{(1)}, \dots, D_{x,t}^{(r)}, E_{x,t} \right) = \mathbb{E} \left[\frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right) \mid D_{x,t}^{(1)}, \dots, D_{x,t}^{(r)}, E_{x,t} \right].$$

Para simplificar la notación, de ahora en adelante se denotará por $\mathcal{D}_{x,t}$ a los conteos de defunciones por causa junto con la exposición correspondiente de la celda x, t . Por tanto, la esperanza anterior se escribirá simplemente como

$$\mathbb{E}[Q_{x,t}^{(c)} \mid \mathcal{D}_{x,t}]$$

Note que $Q_{x,t}^{(c)} = f(\mu_{x,t}^{(1)}, \dots, \mu_{x,t}^{(r)})$ y en general se tiene que

$$\mathbb{E} \left[f \left(\mu_{x,t}^{(1)}, \dots, \mu_{x,t}^{(r)} \right) \mid \mathcal{D}_{x,t} \right] \neq f \left(\mathbb{E} \left[\mu_{x,t}^{(1)} \mid \mathcal{D}_{x,t} \right], \dots, \mathbb{E} \left[\mu_{x,t}^{(r)} \mid \mathcal{D}_{x,t} \right] \right).$$

Por esta razón, no se estimará $Q_{x,t}^{(c)}$ substituyendo directamente las medias posteriores de las intensidades en la fórmula presentada. En su lugar, se deberán hacer simulaciones y aproximar la media posterior de las probabilidades de decrementos mediante Ley de los Grandes Números, esto se hará de la siguiente manera:

Para cada celda (x, t) y para cada simulación $s = 1, \dots, S$, se generan intensidades posteriores por causa:

$$\mu_{x,t}^{(j,s)} \sim \text{Gamma} \left(\hat{\alpha}_p^{(j)} + D_{x,t}^{(j)}, \hat{\beta}_p^{(j)} + E_{x,t} \right), \quad j = 1, \dots, r.$$

Luego, para esa misma simulación, se calcula la intensidad total simulada:

$$\mu_{x,t}^{(\tau,s)} = \sum_{j=1}^r \mu_{x,t}^{(j,s)}.$$

Con estas intensidades simuladas se obtiene una realización posterior de la probabilidad de decremento por causa c :

$$q_{x,t}^{(c,s)} = \frac{\mu_{x,t}^{(c,s)}}{\mu_{x,t}^{(\tau,s)}} \left(1 - e^{-\mu_{x,t}^{(\tau,s)}} \right).$$

Después de S simulaciones, para cada causa c se obtiene una muestra de la forma

$$q_{x,t}^{(c,1)}, \dots, q_{x,t}^{(c,S)}.$$

Para S grande se tiene que el estimador bayesiano de $Q_{x,t}^{(c)}$ de dicha causa c se aproxima entonces como la media muestral de dicho conjunto:

$$q_{x,t}^{(c)*} = \frac{1}{S} \sum_{s=1}^S q_{x,t}^{(c,s)} \approx \mathbb{E} \left(Q_{x,t}^{(c)} \mid \mathcal{D}_{x,t} \right).$$

Esta aproximación se justifica por la Ley de los Grandes Números.

1.2.5. Análisis fallido

Estimación bayesiana sin distinguir el dominio de las causas

En una primera implementación del enfoque bayesiano, los hiperparámetros $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ se estimaron utilizando, para cada país y causa, todas las combinaciones disponibles de sexo, grupo etario y año calendario. Este procedimiento no distinguía entre los ceros observacionales, correspondientes a celdas en las que la muerte por una causa era posible pero no se registraron defunciones, y las celdas situadas fuera del dominio de aplicación definido para determinadas causas.

El problema se hizo evidente para la causa XV, correspondiente a embarazo, parto y puerperio. En la implementación inicial se incorporaron al ajuste las celdas de hombres y mujeres de todos los grupos etarios. Los conteos nulos de las celdas masculinas fueron tratados como observaciones ordinarias de intensidades pequeñas y, por tanto, participaron en la estimación de los hiperparámetros colectivos del país y la causa.

Una vez estimados estos hiperparámetros, las intensidades posteriores se obtenían mediante

$$\mu_{x,t,s}^{(XV)} \mid D_{x,t,s}^{(XV)}, E_{x,t,s} \sim \text{Gamma} \left(\hat{\alpha}_p^{(XV)} + D_{x,t,s}^{(XV)}, \hat{\beta}_p^{(XV)} + E_{x,t,s} \right).$$

Como la distribución Gamma tiene soporte en los reales positivos, una celda masculina con cero defunciones no producía automáticamente una intensidad posterior igual a cero. Por tanto, al transformar posteriormente las intensidades en probabilidades de decremento, el procedimiento podía asignar una probabilidad positiva de morir por embarazo, parto y puerperio a un hombre.

La inclusión de estas celdas también modificaba las estimaciones correspondientes a las mujeres. Pues los numerosos conteos nulos de los hombres (ceros estructurales) alteraban $\hat{\alpha}_p^{(XV)}$ y $\hat{\beta}_p^{(XV)}$, haciendo que fueran muy pequeños y, por tanto, disminuían sintéticamente la estimación bayesiana aplicada a las celdas femeninas en las que la causa sí era aplicable.

Una dificultad análoga apareció para la causa XVI, afecciones originadas en el periodo perinatal. La estimación inicial combinaba las celdas del grupo 0-4, donde se concentraban todas las defunciones observadas de la base de datos, con miles de conteos nulos correspondientes

a edades posteriores. De esta manera, un mismo par de hiperparámetros debía representar simultáneamente la experiencia infantil y una sucesión extensa de ceros en los demás grupos etarios.

Como consecuencia, la distribución colectiva utilizada para estimar las intensidades del grupo 0-4 era influida por celdas ajenas al dominio de la causa, (posteriormente definido) y de manera sintética hacían que las intensidades fueran muy bajas. Además, el modelo podía generar intensidades positivas por afecciones perinatales en edades avanzadas.

El análisis se consideró fallido al inspeccionar los hiperparámetros estimados y las intensidades posteriores por sexo y grupo etario.

A partir de este resultado se reconsideró la metodología. Para la causa XV se definió

$$\mathcal{J}_p^{(XV)} = \left\{ (\text{Mujer}, x, t) : \begin{array}{l} x \in \{10-14, 15-19, \dots, 50-54\}, \\ t \in \{2015, 2016, 2017, 2018\} \end{array} \right\}.$$

Para la causa XVI se definió

$$\mathcal{J}_p^{(XVI)} = \{(s, 0-4, t) : s \in \{\text{Hombre}, \text{Mujer}\}, \quad t \in \{2015, 2016, 2017, 2018\}\}.$$

Las celdas situadas fuera de estos conjuntos dejaron de utilizarse para estimar los hiperparámetros. En cambio, los conteos iguales a cero observados dentro de los conjuntos aplicables se conservaron, pues sí representan información estadística relevante sobre la intensidad de mortalidad.

Comparación de la implementación inicial y la corregida

Para documentar el problema se reproducen los dos procedimientos utilizados. El primero estima los hiperparámetros con la base completa. El segundo aplica las restricciones previamente definidas a las causas XV y XVI.

Tabla 2: Comparación de los hiperparámetros antes y después de restringir los dominios de las causas XV y XVI.

Causa	Celdas iniciales	Celdas corregidas	Alpha inicial	Alpha corregido	Beta inicial	Beta corregido
XV	160	36	0.189284	1.867492	68 784.25	195 936.01
XVI	160	8	0.009020	116.413426	229.26	149 513.70

La Tabla 2 muestra cómo cambian los hiperparámetros cuando la experiencia colectiva se restringe a las celdas aplicables. En el procedimiento inicial, las causas XV y XVI utilizaban

todas las combinaciones disponibles de sexo, grupo etario y año. En el procedimiento corregido, la causa XV utiliza solamente mujeres de 10-14 a 50-54, mientras que la causa XVI utiliza solamente el grupo 0-4.

Para observar cómo el cambio en los hiperparámetros afecta las celdas individuales, se compara también la media posterior de la intensidad:

$$\mathbb{E} \left(\mu_{x,t,s}^{(c)} \mid D_{x,t,s}^{(c)}, E_{x,t,s} \right) = \frac{\hat{\alpha}_p^{(c)} + D_{x,t,s}^{(c)}}{\hat{\beta}_p^{(c)} + E_{x,t,s}}.$$

Tabla 3: Comparación de las medias posteriores de las intensidades en casos representativos.

Caso	Muertes	Exposición	Media posterior inicial	Media posterior corregida
XV: hombre de 25-29	0	210 403	0.000000678	0.000000000
XV: mujer de 25-29	3	203 888	0.000011696	0.000012174
XVI: hombre de 0-4	143	176 002	0.000811485	0.000796931
XVI: hombre de 70-74	0	58 480	0.000000154	0.000000000

La Tabla 3 permite observar directamente el problema de la implementación inicial. Para la causa XV en un hombre de 25-29, la media posterior inicial es positiva aunque estos hombres presenten ceros estructurales. En el procedimiento corregido, la celda se encuentra fuera de $\mathcal{J}_p^{(XV)}$ y su intensidad se fija en cero.

Para una mujer de 25-29, la celda permanece dentro del dominio de la causa XV. Sin embargo, su media posterior cambia porque ahora los hiperparámetros se estiman sin incorporar las celdas masculinas ni los grupos etarios situados fuera del dominio.

En el caso de la causa XVI, la celda del grupo 0-4 permanece dentro del ajuste, pero su media posterior cambia al dejar de utilizarse las edades posteriores para estimar la experiencia colectiva. Por el contrario, la celda de 70-74 queda fuera del dominio adoptado para esta causa y su intensidad corregida se fija en cero.

Referencias