

Bitácora 3

Universidad de Costa Rica

Escuela de Matemática

Departamento de Matemática y Ciencias Actuariales

Proyecto de Investigación

**Análisis del cambio de la probabilidad de decremento
 ${}_nq_x^{(c)}$ para grupos etarios por causas de muerte de
acuerdo a la clasificación ICD-10 en países de
Centroamérica [2015, 2018].**

Integrantes

Sebastián Miranda Ramírez C4H274

Benjamín Gutiérrez Padua C4F813

Kevin David Calderón Martínez C4D511

Gabriel de Jesús Chaves Esquivel C4E273

Profesor

Maikol Solís Chacón

2026

Bitácora 3

1. Parte de Planificación

1.2.1. Formulación metodológica del proyecto

La metodología del proyecto se construye alrededor de estimar la probabilidad actuarial de decremento por causa,

$${}_nq_{x,t}^{(c)} = P(T_{x,t} \leq n, J = c),$$

donde x representa el del grupo etario de cada persona y t el año calendario en el cual se encuentran,

$$x \in \{0, 1, 2, 3, 4, 5-9, 10-14, \dots, 90-94, 95+\}, \quad t \in \{2015, 2016, 2017, 2018\}$$

y c una categoría de causa de muerte según la ICD-10, de acuerdo con la clasificación definida en bitácoras anteriores. En particular, cuando el grupo etario se denote por su edad inicial, x también puede leerse como el extremo inferior del intervalo. Por ejemplo, para el grupo 30-34 se puede escribir $x = 30$ y asociar el intervalo $I_x = [30, 35)$, esta convención se usará al escribir las diversas fórmulas a estimar.

La variable aleatoria $T_{x,t}$ representa el tiempo futuro de vida de una persona perteneciente al grupo etario x durante el año calendario t y J es una variable aleatoria que indica la causa del decremento. Con esta convención, $q_{x,t}^{(c)}$ debe leerse como la probabilidad de morir por la causa c para una vida perteneciente al grupo etario x durante el año calendario t , bajo las intensidades estimadas para esa celda. Por ejemplo, si $x = 30-34$, entonces $q_{30-34,t}^{(c)}$ no se interpreta como la probabilidad exacta de una persona de edad puntual 30, 33.9 o 34.7, sino como el riesgo anual asociado al grupo etario completo 30-34 durante el año t . Asimismo se considera que para que alguien muera por la causa c primero debe no haber muerto por las otras $c - 1$ causas, de manera que estas se consideran “causas competidoras” e influyen en el cálculo de las diferentes probabilidades. Bowers et al. (1997) y Deshmukh (2012) presentan este tratamiento para las probabilidades de decremento.

Aunque el objeto de estudio también depende del país y del sexo, estas dimensiones se mantienen en el cálculo, pero se omiten de la expresión para no sobrecargar la notación, en el momento de presentación de resultados se hará explícito el sexo y el país al que se esté refiriendo cada aseveración. De forma más general, la probabilidad podría escribirse como ${}_nq_{x,t,p,s}^{(c)}$, donde p representa el país y s el sexo.

Con respecto al sistema de clasificación de las causas de defunción: Existe una estandarización aún más general para la clasificación de enfermedades utilizando números romanos, la cual

fue propuesta por la misma WHO, para agrupar de manera más amplia la causa de muerte en el cálculo de las tablas de vida de decrementos múltiples. Para efectos de este trabajo, se utilizará este estándar para un mejor manejo de datos. A continuación una tabla que explica el estándar:

Tabla 1: *Explicación de la lista de tabulación de mortalidad de la ICD-10. Obtenido de: World Health Organization (WHO)*

Grupo	ICD-10	Causa
I	A00-B99, R75	Enfermedades infecciosas y parasitarias
II	C00-D48	Tumores
III	D50-D89	Enfermedades de la sangre y de los órganos hematopoyéticos, y ciertos trastornos que afectan al mecanismo de la inmunidad
IV	E00-E90	Enfermedades endocrinas, nutricionales y metabólicas
V-VIII	F00-H95	Trastornos mentales y del comportamiento (V) y Enfermedades del sistema nervioso y de los órganos de los sentidos (VI-VIII)
IX	I00-I99	Enfermedades del sistema circulatorio
X	J00-J99	Enfermedades del sistema respiratorio
XI	K00-K93	Enfermedades del sistema digestivo
XII	L00-L99	Enfermedades de la piel y del tejido subcutáneo
XIII	M00-M99	Enfermedades del sistema osteomuscular y del tejido conjuntivo
XIV	N00-N99	Enfermedades del sistema genitourinario
XV	O00-O99	Embarazo, parto y puerperio
XVI	P00-P96	Afecciones originadas en el periodo perinatal
XVII	Q00-Q99	Malformaciones congénitas, deformidades y anomalías cromosómicas
XVIII	R00-R74, R76-R99, U00-U99	Síntomas, signos y hallazgos anormales clínicos y de laboratorio, no clasificados en otra parte.
XX	V01-Y89	Causas externas de mortalidad

Para la estimación de estas causas se deberá de recurrir a los datos disponibles en la WHO Mortality Database, los cuales se presentan de manera agregada, por tanto la unidad de análisis será una celda definida por país y sexo dados, así como año calendario t , grupo etario x y causa de muerte c . Para cada celda se tendrá un conteo de defunciones,

$$D_{x,t}^{(c)},$$

obtenido de la WHO Mortality Database, y una exposición en años-persona,

$$E_{x,t},$$

aproximada mediante la población a mitad de año correspondiente al mismo país, sexo, año calendario y grupo etario, obtenida de World Population Prospects 2024. Esta aproximación es metodológicamente razonable en este contexto, pues la población a mitad de año suele utilizarse como aproximación de la exposición al riesgo cuando se trabaja con datos agregados anuales; Pitacco et al. (2009) discuten esta interpretación de la exposición en modelos de mortalidad.

Antes de pasar a los enfoques de estimación, es necesario aclarar con mayor precisión los supuestos bajo los cuales se interpretará el objeto actuarial del proyecto. En este sentido, la notación actuarial general ${}_nq_{x,t}^{(c)}$ es útil para introducir la idea de probabilidad de decremento por causa, y además es cercana a la notación estándar utilizada en trabajos sobre probabilidades de decrementos múltiples. En una formulación actuarial más general, para trabajar con ${}_nq_{x',t'}^{(c)}$ se puede interpretar x' como una edad exacta y t' como un momento exacto del calendario. Sin embargo, en dichos trabajos se suele contar con maneras precisas de estimar las probabilidades ${}_nq_{x',t'}^{(c)}$, para al menos todos los x', t' enteros, de manera que mediante supuestos como fuerza de mortalidad constante en cada celda $[x', x' + 1)$ y $[t', t' + 1)$ se pueden estimar toda la familia de probabilidades ${}_nq_{x',t'}^{(c)}$, para x', t', n reales.

Sin embargo, en este trabajo no se cuenta con datos para todas las edades exactas x' ni para todos los momentos calendario t' , debido a la naturaleza agregada de la WHO Mortality Database. Los datos disponibles están agrupados por grupo etario y año calendario, a excepción de los primeros años de vida, donde sí aparecen de manera más desagregada. Por esta razón, en nuestro trabajo x no representa una edad exacta individual, sino que indexa el grupo etario al que pertenece la persona.

Por tanto, el supuesto de fuerza constante no se hará solamente sobre una celda del estilo $[x', x' + 1)$ y $[t', t' + 1)$ para edades exactas, sino sobre todo el intervalo de edad asociado al grupo etario durante un año calendario. Así, para un país y sexo fijados, si I_x representa el grupo etario asociado a x , y si t representa el año calendario, se asumirá que la fuerza de mortalidad por causa es constante dentro de la celda formada por grupo etario y año calendario. Es decir, si

$$I_x = [a_x, b_x),$$

entonces se supondrá que

$$\mu_{y,z}^{(c)} = \mu_{x,t}^{(c)}$$

para edades exactas $y \in I_x$ y momentos calendario $z \in [t, t + 1)$, donde $\mu_{x,t}^{(c)}$ representa la intensidad o tasa central de mortalidad por la causa c para la celda definida por grupo etario x y año calendario t .

En el caso particular de grupos quinquenales, si el grupo se denota por su edad inicial y se escribe $I_x = [x, x + 5)$, el supuesto anterior equivale a asumir que

$$\mu_{x+\xi_1, t+\xi_2}^{(c)} = \mu_{x, t}^{(c)}, \quad 0 \leq \xi_1 < 5, \quad 0 \leq \xi_2 < 1.$$

En otras palabras, $\mu_{x, t}^{(c)}$ no representa una intensidad propia de una edad exacta como 33.9, sino la intensidad estimada para todo el grupo etario x durante el año t . Por ejemplo, si $x = 30$ representa el grupo 30-34, entonces $\mu_{30, t}^{(c)}$ representa una única intensidad asociada al intervalo $I_{30} = [30, 35)$ durante el año calendario t .

Esta aclaración es importante porque ${}_n q_{x, t}^{(c)}$, para un horizonte general n , solo puede usarse directamente con una única intensidad de muerte cuando el intervalo considerado permanece dentro de la celda donde esa intensidad fue asumida constante. Si una persona tuviera una edad exacta $y \in I_x$ y se quisiera seguir durante n años usando solamente $\mu_{x, t}^{(c)}$, tendría que cumplirse al menos que

$$y + n \leq b_x.$$

Si esta condición no se cumple, la persona saldría del grupo etario I_x y entraría en otro grupo, por lo que ya no sería correcto usar únicamente la intensidad $\mu_{x, t}^{(c)}$. Además, aun si se cumpliera la condición anterior respecto al grupo etario, también habría que considerar el año calendario si el seguimiento se interpretara estrictamente como una trayectoria real en edad y calendario, pues el año t cambiaría al avanzar el tiempo. En ese caso, la fórmula directa con una sola intensidad tendría que sustituirse por un encadenamiento por tramos, usando las intensidades correspondientes a los grupos etarios y años calendario que se vayan cruzando.

Por esta razón, en la aplicación empírica del proyecto se fijará el horizonte en $n = 1$, pues esta elección es la más coherente con la estructura anual de los datos, y hace que el proyecto sea computacionalmente estable y fácilmente interpretable. Una vez hecha esta salvedad, se escribirá simplemente

$$q_{x, t}^{(c)}$$

para referirse a la probabilidad anual de decremento por causa. Es decir,

$$q_{x, t}^{(c)} := {}_1 q_{x, t}^{(c)}.$$

Con esta convención, $q_{x, t}^{(c)}$ debe leerse como una probabilidad anual asociada a la celda agregada definida por grupo etario, año calendario, país, sexo y causa. Es decir, representa el riesgo anual estimado de morir por la causa c para el conjunto de vidas expuestas dentro del grupo etario x durante el año t , bajo las intensidades estimadas para esa celda. Por ejemplo, si $x = 30$

representa el grupo 30-34, entonces $q_{30,t}^{(c)}$ representa el riesgo anual estimado del grupo etario 30-34 durante el año t .

Esta cantidad debe entenderse principalmente como una medida del grupo etario, no como una probabilidad exacta para cada edad individual dentro del grupo. Si una persona tuviera una edad exacta dentro de ese intervalo, por ejemplo 31.2 o 32.5, el modelo simplemente la ubicaría dentro del grupo 30-34 y le asociaría la misma intensidad estimada para todo el grupo. Esto ocurre porque los datos no permiten distinguir el riesgo de cada edad exacta por separado. Así, bajo el supuesto de fuerza constante dentro de la celda, edades internas como 30, 31.2, 32.5 o incluso 33.9 quedan representadas por la misma probabilidad grupal $q_{30,t}^{(c)}$, pero no se está haciendo una estimación exacta para cada edad individual.

Con estas salvedades aclaradas, es esencial definir de qué manera se estimará $q_{x,t}^{(c)}$. Para seguir la línea del curso y los métodos allí vistos, se usará tanto un enfoque clásico como uno bayesiano. En este sentido, la comparación no será el fin del proyecto por sí misma, sino un medio para interpretar patrones de variabilidad. Si una celda tiene alta exposición y suficientes defunciones, ambos enfoques deberían producir resultados similares. Si una celda tiene baja exposición, conteos nulos o una causa poco frecuente, el enfoque bayesiano debería producir estimaciones más estabilizadas e intervalos más amplios. El por qué de estos resultados esperados se hará claro conforme se definan los métodos de estimación que se tomará en cada uno de los enfoques.

Enfoque clásico

El primer bloque metodológico será clásico. Para cada celda se modelarán las defunciones por causa como una variable aleatoria de conteo:

$$D_{x,t}^{(c)} \mid \mu_{x,t}^{(c)} \sim \text{Poisson} \left(E_{x,t} \mu_{x,t}^{(c)} \right),$$

Esta formulación se apoya en Manton et al. (1989), argumentan que las defunciones pueden modelarse aproximadamente como una variable Poisson con dichos parámetros. Esto es además coherente con la naturaleza de la distribución Poisson, la cual representa el número de sucesos aleatorios que ocurren en un intervalo de tiempo dado, en este caso dichos sucesos serían las defunciones. Asimismo, $\mu_{x,t}^{(c)}$ se interpreta como la fuerza de mortalidad, es decir, una tasa instantánea de salida del estado vivo por la causa c , asumida constante dentro de la celda anual considerada. Por tanto, al multiplicarla por la exposición $E_{x,t}$, el producto $E_{x,t} \mu_{x,t}^{(c)}$ representa el número esperado de defunciones por la causa c en dicha celda, lo que justifica que sea el parámetro de la Poisson.

Pitacco et al (2009) muestran que, bajo este modelo, la estimación clásica por máxima verosimilitud de la intensidad es

$$\hat{\mu}_{x,t}^{(c)} = \frac{D_{x,t}^{(c)}}{E_{x,t}}.$$

Esta representa cuántas defunciones por la causa c se observan en relación con la población expuesta en esa celda. Luego se construye la fuerza total de salida del estado vivo sumando las intensidades por causa a lo largo de las r causas:

$$\mu_{x,t}^{(\tau)} = \sum_{j=1}^r \mu_{x,t}^{(j)}.$$

La notación (τ) se usa para indicar la mortalidad total por todas las causas consideradas. Esta suma es la parte que hace que el enfoque sea realmente de decrementos múltiples en presencia de causas competitivas, como se mencionó antes, la causa c no se analiza como si fuera la única causa posible, sino en presencia de las demás causas que también pueden producir la muerte dentro del intervalo.

Bajo el supuesto de fuerza constante dentro de la celda anual considerada, la transformación de intensidades a probabilidades de decremento se aplica directamente para el horizonte anual del proyecto. Siguiendo la fórmula de decrementos múltiples bajo fuerza constante presentada por Deshmukh (2012, p. 46), la probabilidad anual de morir por la causa c se expresa como

$$q_{x,t}^{(c)} = \frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right).$$

En consecuencia, la estimación clásica será

$$\hat{q}_{x,t}^{(c)} = \frac{\hat{\mu}_{x,t}^{(c)}}{\hat{\mu}_{x,t}^{(\tau)}} \left(1 - e^{-\hat{\mu}_{x,t}^{(\tau)}} \right).$$

Análisis de las probabilidades de decremento desde el enfoque clásico

Una vez estimadas las probabilidades clásicas de decremento por causa, se construyen tres análisis derivados: La probabilidad de decremento por causa, la composición causal condicionada al fallecimiento y la concentración causal. Estos análisis constituyen un enfoque probabilístico que compara entre sí las causas de decremento. Su propósito es responder la pregunta planteada inicialmente; cómo varía la probabilidad de decremento por causa según grupo etario, país, sexo y año calendario.

Inicialmente, el primer análisis gráfico corresponde a la probabilidad de decremento por causa,

$$\hat{q}_{x,t}^{(c)}.$$

Esta cantidad mide la magnitud real del riesgo de decremento por causa. En la presentación gráfica se plantea utilizar

$$100\hat{q}_{x,t}^{(c)},$$

de manera que el eje vertical pueda interpretarse como porcentaje. Este análisis permite comparar, para cada país y sexo, cómo cambia la probabilidad anual de fallecer por una causa específica entre 2015 y 2018 a lo largo de los grupos etarios.

El segundo análisis corresponde a la composición causal condicionada al fallecimiento. Para una celda fija, la probabilidad total de fallecimiento por cualquier causa es

$$\hat{q}_{x,t}^{(\tau)} = \sum_{j=1}^r \hat{q}_{x,t}^{(j)}.$$

A partir de esta cantidad se define la composición causal condicionada al fallecimiento. Para justificarla, considérese, para una celda fija, el evento

$$A_c = \{T_{x,t} \leq 1, J = c\},$$

correspondiente a fallecer durante un horizonte anual por la causa c , y el evento

$$B = \{T_{x,t} \leq 1\},$$

correspondiente a fallecer durante ese mismo horizonte anual por cualquier causa. Por definición,

$$P(A_c) = \hat{q}_{x,t}^{(c)}.$$

Como las causas son mutuamente excluyentes y exhaustivas, el evento B es la unión disjunta de los eventos $A_1, \dots, A_r$. Por tanto,

$$P(B) = \sum_{j=1}^r P(A_j) = \sum_{j=1}^r \hat{q}_{x,t}^{(j)} = \hat{q}_{x,t}^{(\tau)}.$$

Además, como $A_c \subseteq B$, se tiene $A_c \cap B = A_c$. Así, mediante la definición de probabilidad condicional considere

$$\pi_{x,t}^{(c)} := P(J = c \mid T_{x,t} \leq 1) = \frac{P(A_c \cap B)}{P(B)} = \frac{q_{x,t}^{(c)}}{\sum_{j=1}^r q_{x,t}^{(j)}}.$$

Al sustituir las probabilidades desconocidas por sus estimaciones, se obtiene

$$\hat{\pi}_{x,t}^{(c)} = \frac{\hat{q}_{x,t}^{(c)}}{\sum_{j=1}^r \hat{q}_{x,t}^{(j)}}.$$

La condición $T_{x,t} \leq 1$ modifica el conjunto de referencia sobre el cual se calcula la probabilidad. Sin condicionar, $q_{x,t}^{(c)}$ considera a todas las vidas pertenecientes a la celda y mide la probabilidad de que una de ellas fallezca por la causa c durante el horizonte anual. En cambio, al condicionar a que $T_{x,t} \leq 1$, se excluyen del conjunto de referencia todas las vidas que sobreviven ese año y se consideran únicamente aquellas que fallecen.

Por tanto,

$$\pi_{x,t}^{(c)} = P(J = c \mid T_{x,t} \leq 1)$$

responde a la siguiente pregunta: dado que una vida perteneciente a la celda (x, t) fallece durante el próximo año, ¿cuál es la probabilidad de que ese fallecimiento sea atribuible a la causa c ?

Así, $\hat{q}_{x,t}^{(c)}$ mide un riesgo absoluto respecto de todas las vidas de la celda, mientras que $\hat{\pi}_{x,t}^{(c)}$ mide una composición causal respecto únicamente de las vidas que fallecen. Por ejemplo, si la probabilidad anual total de fallecimiento es 0.02 y la probabilidad de fallecer por la causa c es 0.006, entonces

$$\hat{\pi}_{x,t}^{(c)} = \frac{0.006}{0.02} = 0.30.$$

Esto no significa que el 30 % de las vidas de la celda fallezca por la causa c , sino que, entre los fallecimientos ocurridos durante el horizonte anual, el 30 % se atribuye probabilísticamente a dicha causa.

Asimismo es importante notar que para una celda fija, las cantidades estimadas $\hat{\pi}_{x,t}^{(c)}$ forman una distribución de probabilidad sobre las causas, ya que

$$\sum_{c=1}^r \hat{\pi}_{x,t}^{(c)} = \sum_{c=1}^r \frac{\hat{q}_{x,t}^{(c)}}{\sum_{j=1}^r \hat{q}_{x,t}^{(j)}} = 1.$$

Porque, una vez condicionado a que ocurrió un fallecimiento, la persona necesariamente tuvo que morir por una de las r causas consideradas. Por tanto, las probabilidades condicionadas distribuyen la totalidad de la probabilidad entre las causas.

Esta propiedad justifica el uso de gráficos de composición condicionada, similares en espíritu a los análisis de distribución de causas de muerte por grupo de edad, utilizados por Goerlich (2012, p.36). Sin embargo, para mantener la legibilidad, se propone mostrar únicamente algunas causas seleccionadas. En estos casos, el denominador de $\hat{\pi}_{x,t}^{(c)}$ continuará incluyendo la suma de las probabilidades de decremento correspondientes a todas las causas, aunque solo se visualicen algunas. Por esta razón, cuando se presenten únicamente causas seleccionadas, las barras visibles no necesariamente sumarían 100 %.

El tercer análisis resume la concentración de la composición causal. Dado que $\hat{\pi}_{x,t}^{(c)}$ define una distribución de probabilidad sobre las causas de muerte, se calcula el índice

$$H_{x,t} = \sum_{c=1}^r \left(\hat{\pi}_{x,t}^{(c)} \right)^2 = \sum_{c=1}^r \left(\frac{\hat{q}_{x,t}^{(c)}}{\sum_{j=1}^r \hat{q}_{x,t}^{(j)}} \right)^2.$$

Este índice es una medida tipo Herfindahl-Simpson aplicada a la composición causal. Su valor se encuentra entre $1/r$ y 1. Valores altos indican que la mortalidad de la celda está concentrada en pocas causas; valores bajos indican que la mortalidad está más distribuida entre varias causas [Simpson1949; Herfindahl1950; Hirschman1964].

La interpretación probabilística de $H_{x,t}$ es directa. Si se seleccionan dos fallecimientos de manera independiente dentro de la misma celda, y si la probabilidad de que un fallecimiento corresponda a la causa c es $\hat{\pi}_{x,t}^{(c)}$, entonces la probabilidad de que ambos fallecimientos correspondan a la misma causa es

$$\sum_{c=1}^r \hat{\pi}_{x,t}^{(c)} \hat{\pi}_{x,t}^{(c)} = \sum_{c=1}^r \left(\hat{\pi}_{x,t}^{(c)} \right)^2 = H_{x,t}.$$

Por tanto, $H_{x,t}$ no se introduce únicamente como un indicador descriptivo, sino como una función de la distribución condicional de causas. En el contexto del proyecto, permite identificar si la mortalidad de un grupo etario está dominada por una causa particular o si se reparte entre múltiples categorías.

En conjunto, los tres análisis cumplen funciones complementarias. La probabilidad absoluta $\hat{q}_{x,t}^{(c)}$ permite analizar la magnitud del decremento por causa. La composición condicionada $\hat{\pi}_{x,t}^{(c)}$ permite estudiar la estructura causal de las muertes dentro de cada grupo etario. Finalmente, el índice $H_{x,t}$ resume el grado de concentración de dicha estructura causal. Así, los gráficos utilizados no se plantean como visualizaciones aisladas, sino como representaciones de cantidades probabilísticas derivadas del modelo clásico de decrementos múltiples.

Para efectos de visualización, las causas principales se seleccionan por país. Se incluye la categoría de causas externas de mortalidad debido a su relevancia en edades jóvenes y adultas, y se completan las restantes con las causas de mayor probabilidad promedio de decremento dentro del país. Además, las afecciones originadas en el periodo perinatal se analizan por separado, dado que presentan un perfil etario estructuralmente distinto, concentrado en edades iniciales. Esta selección afecta únicamente la presentación gráfica; los denominadores utilizados en $\hat{q}_{x,t}^{(\tau)}$, $\hat{\pi}_{x,t}^{(c)}$ y $H_{x,t}$ se calculan con todas las causas disponibles en cada celda.

Enfoque bayesiano

El enfoque bayesiano mantiene el mismo modelo de conteo usado en el enfoque clásico, de forma que:

$$D_{x,t}^{(c)} \mid \mu_{x,t}^{(c)} \sim \text{Poisson} \left(E_{x,t} \mu_{x,t}^{(c)} \right).$$

Sin embargo ahora la intensidad de mortalidad por causa se considera una variable aleatoria. La diferencia respecto al enfoque clásico es que ahora $\mu_{x,t}^{(c)}$ no se trata como un parámetro fijo desconocido, sino como una variable aleatoria positiva. Para ello se asigna una distribución Gamma:

$$\mu_{x,t}^{(c)} \sim \text{Gamma} \left(\alpha_p^{(c)}, \beta_p^{(c)} \right), \quad \mathbb{E} \left[\mu_{x,t}^{(c)} \right] = \frac{\alpha_p^{(c)}}{\beta_p^{(c)}}.$$

Se debe recordar que, aunque en buena parte de la metodología se omiten el país y el sexo de la notación para evitar sobrecargarla, la estimación se realiza utilizando celdas definidas por país, sexo, grupo etario, año calendario y causa. En el caso de los hiperparámetros sí se mantendrá explícito el país p , ya que se estimará un par distinto para cada combinación de país y causa:

$$\alpha_p^{(c)}, \beta_p^{(c)}.$$

Estos hiperparámetros serán comunes para los distintos sexos, grupos etarios y años calendario incluidos en la experiencia colectiva del país p y la causa c . Es decir, para cada país y causa se utilizará la información observada en ambos sexos, los distintos grupos etarios y los años 2015 a 2018, pero el resultado será un único par de hiperparámetros.

Para formalizar esta idea, se define

$$\mathcal{J}_p^{(c)} = \{(s, x, t) : \text{país } p \text{ y causa } c \text{ fijos}\},$$

donde s representa el sexo, x el grupo etario y t el año calendario. Por tanto, $\mathcal{J}_p^{(c)}$ contiene las celdas cuya experiencia se utilizará para estimar los hiperparámetros correspondientes al país p y la causa c .

Para la mayoría de las causas, el conjunto $\mathcal{J}_p^{(c)}$ incluirá todas las combinaciones disponibles de sexo, grupo etario y año calendario. Sin embargo, antes de realizar la estimación es necesario distinguir entre ceros observacionales y ceros estructurales.

Un cero observacional corresponde a una celda en la cual la muerte por la causa c es posible, pero no se registraron defunciones durante el año analizado. Estas celdas deben mantenerse en la estimación, ya que aportan información sobre la intensidad de mortalidad.

En cambio, un cero estructural corresponde a una combinación de sexo o grupo etario para la cual la causa no resulta aplicable. Estas celdas no deben interpretarse como observaciones de una intensidad pequeña, sino como casos que se encuentran fuera del conjunto de riesgo correspondiente a la causa.

En particular, para la causa XV, correspondiente a embarazo, parto y puerperio, se define

$$\mathcal{J}_p^{(XV)} = \left\{ (\text{Mujer}, x, t) : \begin{array}{l} x \in \{10-14, 15-19, \dots, 50-54\}, \\ t \in \{2015, 2016, 2017, 2018\} \end{array} \right\}.$$

Por tanto, para esta causa no se utilizarán en la estimación de los hiperparámetros las celdas correspondientes a hombres ni los grupos etarios situados fuera de dicho intervalo. No obstante, los conteos iguales a cero que aparezcan dentro de las celdas femeninas incluidas sí permanecerán en la estimación.

Para la causa XVI, afecciones originadas en el periodo perinatal, se define

$$\mathcal{J}_p^{(XVI)} := \{(s, 0-4, t) : s \in \{\text{Hombre}, \text{Mujer}\}, \quad t \in \{2015, 2016, 2017, 2018\}\}.$$

En este caso, la estimación utilizará solamente las celdas correspondientes al grupo etario 0-4, para ambos sexos y todos los años disponibles. Los conteos nulos observados dentro de estas celdas también se conservarán.

Así, las restricciones anteriores no implican eliminar de manera general las observaciones para las cuales

$$D_{x,t,s}^{(c)} = 0.$$

Únicamente se excluyen las celdas que se encuentran fuera del dominio de aplicación de la causa.

Esto permite mantener la idea de experiencia colectiva propia del enfoque Empirical Bayes. Cada celda conserva su información observada, pero la estimación de su intensidad se beneficia de la experiencia conjunta del país y la causa. Esta característica resulta especialmente útil cuando existen celdas con poca exposición, conteos pequeños o conteos nulos.

Estimación de $\alpha_p^{(c)}$ y $\beta_p^{(c)}$

Los hiperparámetros $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ se estimarán mediante un enfoque Empirical Bayes, inspirado en el procedimiento presentado por Zhang et al. (2019). Esto significa que no se fijarán subjetivamente, sino que se estimarán a partir de los conteos observados pertenecientes al conjunto $\mathcal{J}_p^{(c)}$.

El modelo bayesiano puede representarse mediante la jerarquía

$$\alpha_p^{(c)}, \beta_p^{(c)} \longrightarrow \mu_{x,t,s}^{(c)} \longrightarrow D_{x,t,s}^{(c)}.$$

En el primer nivel, los hiperparámetros $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ describen la experiencia colectiva asociada al país p y a la causa c . En el segundo nivel, cada intensidad $\mu_{x,t,s}^{(c)}$ representa el riesgo latente propio de una celda definida por sexo, grupo etario y año calendario. Finalmente, en el tercer nivel se encuentran los conteos observados $D_{x,t,s}^{(c)}$.

Para cada celda aplicable se mantiene el modelo

$$D_{x,t,s}^{(c)} \mid \mu_{x,t,s}^{(c)} \sim \text{Poisson} \left(E_{x,t,s} \mu_{x,t,s}^{(c)} \right),$$

junto con la distribución previa

$$\mu_{x,t,s}^{(c)} \sim \text{Gamma} \left(\alpha_p^{(c)}, \beta_p^{(c)} \right),$$

donde $\beta_p^{(c)}$ se parametriza como tasa. Por tanto,

$$\mathbb{E} \left[\mu_{x,t,s}^{(c)} \right] = \frac{\alpha_p^{(c)}}{\beta_p^{(c)}}.$$

La dificultad es que las intensidades $\mu_{x,t,s}^{(c)}$ no se observan directamente. Los datos disponibles son las defunciones $D_{x,t,s}^{(c)}$ y las exposiciones $E_{x,t,s}$. Por ello, los hiperparámetros no se estimarán utilizando una muestra observada de intensidades, sino mediante la distribución marginal de los conteos.

Esta distribución se obtiene integrando la intensidad latente:

$$P\left(D_{x,t,s}^{(c)} = d\right) = \int_0^\infty P\left(D_{x,t,s}^{(c)} = d \mid \mu\right) f\left(\mu \mid \alpha_p^{(c)}, \beta_p^{(c)}\right) d\mu.$$

Este procedimiento elimina el nivel intermedio no observado y produce una relación directa entre los hiperparámetros y los conteos:

$$\alpha_p^{(c)}, \beta_p^{(c)} \longrightarrow D_{x,t,s}^{(c)}.$$

Como señalan Schmitt et al. (2019), al integrar la intensidad en el modelo conjugado Poisson–Gamma se obtiene una distribución marginal binomial negativa:

$$P\left(D_{x,t,s}^{(c)} = d\right) = \frac{\Gamma\left(\alpha_p^{(c)} + d\right)}{\Gamma\left(\alpha_p^{(c)}\right) d!} \left(\frac{\beta_p^{(c)}}{\beta_p^{(c)} + E_{x,t,s}}\right)^{\alpha_p^{(c)}} \left(\frac{E_{x,t,s}}{\beta_p^{(c)} + E_{x,t,s}}\right)^d.$$

Siguiendo la lógica Empirical Bayes descrita por Zhang et al. (2019), los hiperparámetros se estimarán mediante máxima verosimilitud marginal. Para cada país p y causa c , se construye la log-verosimilitud

$$\begin{aligned} \ell_p^{(c)}(\alpha, \beta) = \sum_{(s,x,t) \in \mathcal{J}_p^{(c)}} & \left[\log \Gamma\left(\alpha + D_{x,t,s}^{(c)}\right) - \log \Gamma(\alpha) - \log\left(D_{x,t,s}^{(c)}!\right) \right. \\ & \left. + \alpha \log\left(\frac{\beta}{\beta + E_{x,t,s}}\right) + D_{x,t,s}^{(c)} \log\left(\frac{E_{x,t,s}}{\beta + E_{x,t,s}}\right) \right]. \end{aligned}$$

Por tanto, para cada país p y causa c , los estimadores Empirical Bayes se definen como

$$\left(\hat{\alpha}_p^{(c)}, \hat{\beta}_p^{(c)}\right) = \arg \max_{\alpha > 0, \beta > 0} \ell_p^{(c)}(\alpha, \beta).$$

La maximización se realizará numéricamente mediante la función `optim()` de R. Para garantizar que los parámetros permanezcan positivos, la optimización se realizará sobre $\log(\alpha)$ y $\log(\beta)$, recuperando posteriormente los valores de α y β mediante la función exponencial. Esta transformación no modifica el criterio de máxima verosimilitud, sino que facilita la búsqueda numérica respetando las restricciones

$$\alpha > 0, \quad \beta > 0.$$

Una vez estimados los hiperparámetros, para cada celda perteneciente a $\mathcal{J}_p^{(c)}$ se obtiene por conjugación Poisson–Gamma

$$\mu_{x,t,s}^{(c)} \mid D_{x,t,s}^{(c)}, E_{x,t,s} \sim \text{Gamma} \left(\hat{\alpha}_p^{(c)} + D_{x,t,s}^{(c)}, \hat{\beta}_p^{(c)} + E_{x,t,s} \right).$$

Para las celdas situadas fuera de $\mathcal{J}_p^{(c)}$ no se generará una intensidad mediante la distribución Gamma posterior. En la implementación, su contribución a la intensidad total de la celda se fijará en cero y se conservará un indicador que señale que la causa no fue considerada aplicable dentro del dominio definido para el proyecto.

Este valor nulo no debe interpretarse necesariamente como una afirmación general de imposibilidad biológica, sino como una restricción del dominio de modelación adoptado según el sexo, la agrupación etaria y el soporte observado en los datos. La excepción más clara corresponde a la causa XV en hombres, para la cual el cero sí se considera estructural.

En cambio, las celdas pertenecientes a $\mathcal{J}_p^{(c)}$ permanecerán en la estimación incluso cuando $D_{x,t,s}^{(c)} = 0$. En esos casos, la intensidad posterior no se fija en cero, sino que se obtiene mediante

$$\mu_{x,t,s}^{(c)} \mid D_{x,t,s}^{(c)} = 0 \sim \text{Gamma} \left(\hat{\alpha}_p^{(c)} + 0, \hat{\beta}_p^{(c)} + E_{x,t,s} \right).$$

Simulación posterior de $q_{x,t}^{(c)}$

De la explicación brindada en el enfoque clásico y en resonancia con Deshmukh (2012, p. 46) sabemos que:

$$q_{x,t}^{(c)} = \frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right),$$

Sin embargo, como ahora en el enfoque bayesiano cada $\mu_{x,t}^{(j)}$ es una variable aleatoria posterior, entonces la probabilidad de decremento $Q_{x,t}^{(c)}$ también lo es (note que debido a esto ahora se escribirá con una Q mayúscula). Por tanto, al querer estimarla no basta con sustituir directamente las medias posteriores de las intensidades en la fórmula clásica. Esto se debe a que la transformación de intensidades a probabilidades de decremento no es lineal, pues depende de la suma $\mu_{x,t}^{(\tau)} = \sum_{j=1}^r \mu_{x,t}^{(j)}$ dentro de una función exponencial.

Así, bajo función de pérdida cuadrática, el estimador bayesiano de interés es la esperanza posterior de la variable aleatoria $Q_{x,t}^{(c)}$. Debido a que se están usando los r conteos de defunciones (uno por causa) para calcular $\mu_{x,t}^{(\tau)}$, se tiene que dicha esperanza posterior se ve la siguiente manera:

$$\mathbb{E} \left(Q_{x,t}^{(c)} \mid D_{x,t}^{(1)}, \dots, D_{x,t}^{(r)}, E_{x,t} \right) = \mathbb{E} \left[\frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right) \mid D_{x,t}^{(1)}, \dots, D_{x,t}^{(r)}, E_{x,t} \right].$$

Para simplificar la notación, de ahora en adelante se denotará por $\mathcal{D}_{x,t}$ a los conteos de defunciones por causa junto con la exposición correspondiente de la celda x, t . Por tanto, la esperanza anterior se escribirá simplemente como

$$\mathbb{E}[Q_{x,t}^{(c)} \mid \mathcal{D}_{x,t}]$$

Note que $Q_{x,t}^{(c)} = f(\mu_{x,t}^{(1)}, \dots, \mu_{x,t}^{(r)})$ y en general se tiene que

$$\mathbb{E} \left[f \left(\mu_{x,t}^{(1)}, \dots, \mu_{x,t}^{(r)} \right) \mid \mathcal{D}_{x,t} \right] \neq f \left(\mathbb{E} \left[\mu_{x,t}^{(1)} \mid \mathcal{D}_{x,t} \right], \dots, \mathbb{E} \left[\mu_{x,t}^{(r)} \mid \mathcal{D}_{x,t} \right] \right).$$

Por esta razón, no se estimará $Q_{x,t}^{(c)}$ sustituyendo directamente las medias posteriores de las intensidades en la fórmula presentada. En su lugar, se deberán hacer simulaciones y aproximar la media posterior de las probabilidades de decrementos mediante Ley de los Grandes Números, esto se hará de la siguiente manera:

Para cada celda (x, t) y para cada simulación $s = 1, \dots, S$, se generan intensidades posteriores por causa:

$$\mu_{x,t}^{(j,s)} \sim \text{Gamma} \left(\hat{\alpha}_p^{(j)} + D_{x,t}^{(j)}, \hat{\beta}_p^{(j)} + E_{x,t} \right), \quad j = 1, \dots, r.$$

Luego, para esa misma simulación, se calcula la intensidad total simulada:

$$\mu_{x,t}^{(\tau,s)} = \sum_{j=1}^r \mu_{x,t}^{(j,s)}.$$

Con estas intensidades simuladas se obtiene una realización posterior de la probabilidad de decremento por causa c :

$$q_{x,t}^{(c,s)} = \frac{\mu_{x,t}^{(c,s)}}{\mu_{x,t}^{(\tau,s)}} \left(1 - e^{-\mu_{x,t}^{(\tau,s)}} \right).$$

Después de S simulaciones, para cada causa c se obtiene una muestra de la forma

$$q_{x,t}^{(c,1)}, \dots, q_{x,t}^{(c,S)}.$$

Para S grande se tiene que el estimador bayesiano de $Q_{x,t}^{(c)}$ de dicha causa c se aproxima entonces como la media muestral de dicho conjunto:

$$q_{x,t}^{(c)*} = \frac{1}{S} \sum_{s=1}^S q_{x,t}^{(c,s)} \approx \mathbb{E} \left(Q_{x,t}^{(c)} \mid \mathcal{D}_{x,t} \right).$$

Esta aproximación se justifica por la Ley de los Grandes Números.

1.2.5. Análisis fallido

Estimación bayesiana sin distinguir el dominio de las causas

(En esta sección se retoma el subíndice s , correspondiente al sexo en las diversas fórmulas, para hacer claro el punto al cual se hace referencia).

En una primera implementación del enfoque bayesiano, los hiperparámetros $\alpha_p^{(c)}$ y $\beta_p^{(c)}$ se estimaron utilizando, para cada país y causa, todas las combinaciones disponibles de sexo, grupo etario y año calendario. Este procedimiento no distinguía entre los ceros observacionales, correspondientes a celdas en las que la muerte por una causa era posible pero no se registraron defunciones, y las celdas situadas fuera del dominio de aplicación definido para determinadas causas.

El problema se hizo evidente para la causa XV, correspondiente a embarazo, parto y puerperio. En la implementación inicial se incorporaron al ajuste las celdas de hombres y mujeres de todos los grupos etarios. Los conteos nulos de las celdas masculinas fueron tratados como observaciones ordinarias de intensidades pequeñas y, por tanto, participaron en la estimación de los hiperparámetros colectivos del país y la causa.

Una vez estimados estos hiperparámetros, las intensidades posteriores se obtenían mediante

$$\mu_{x,t,s}^{(XV)} \mid D_{x,t,s}^{(XV)} \sim \text{Gamma} \left(\hat{\alpha}_p^{(XV)} + D_{x,t,s}^{(XV)}, \hat{\beta}_p^{(XV)} + E_{x,t,s} \right).$$

Como la distribución Gamma tiene soporte en los reales positivos, una celda masculina con cero defunciones no producía automáticamente una intensidad posterior igual a cero. Por tanto, al transformar posteriormente las intensidades en probabilidades de decremento, el procedimiento podía asignar una probabilidad positiva de morir por embarazo, parto y puerperio a un hombre.

La inclusión de estas celdas también modificaba las estimaciones correspondientes a las mujeres. Pues los numerosos conteos nulos de los hombres (ceros estructurales) alteraban $\hat{\alpha}_p^{(XV)}$ y $\hat{\beta}_p^{(XV)}$, haciendo que fueran muy pequeños y, por tanto, disminuían sintéticamente la estimación bayesiana aplicada a las celdas femeninas en las que la causa sí era aplicable.

Una dificultad análoga apareció para la causa XVI, afecciones originadas en el periodo perinatal. La estimación inicial combinaba las celdas del grupo 0-4, donde se concentraban todas las defunciones observadas de la base de datos, con miles de conteos nulos correspondientes a

edades posteriores. De esta manera, un mismo par de hiperparámetros debía representar simultáneamente la experiencia infantil y una sucesión extensa de ceros en los demás grupos etarios.

Como consecuencia, la distribución colectiva utilizada para estimar las intensidades del grupo 0-4 era influida por celdas ajenas al dominio de la causa, (posteriormente definido) y de manera sintética hacían que las intensidades fueran muy bajas. Además, el modelo podía generar intensidades positivas por afecciones perinatales en edades avanzadas.

El análisis se consideró fallido al inspeccionar los hiperparámetros estimados y las intensidades posteriores por sexo y grupo etario.

A partir de este resultado se reconsideró la metodología. Para la causa XV se definió

$$\mathcal{J}_p^{(XV)} = \left\{ (\text{Mujer}, x, t) : \begin{array}{l} x \in \{10-14, 15-19, \dots, 50-54\}, \\ t \in \{2015, 2016, 2017, 2018\} \end{array} \right\}.$$

Para la causa XVI se definió

$$\mathcal{J}_p^{(XVI)} = \{(s, 0-4, t) : s \in \{\text{Hombre}, \text{Mujer}\}, \quad t \in \{2015, 2016, 2017, 2018\}\}.$$

Las celdas situadas fuera de estos conjuntos dejaron de utilizarse para estimar los hiperparámetros. En cambio, los conteos iguales a cero observados dentro de los conjuntos aplicables se conservaron, pues sí representan información estadística relevante sobre la intensidad de mortalidad.

Comparación de la implementación inicial y la corregida

Para documentar el problema se reproducen los dos procedimientos utilizados. El primero estima los hiperparámetros con la base completa. El segundo aplica las restricciones previamente definidas a las causas XV y XVI.

Tabla 2: Comparación de los hiperparámetros antes y después de restringir los dominios de las causas XV y XVI.

Cau- sa	Celdas iniciales	Celdas corregidas	Alpha inicial	Alpha corregido	Beta inicial	Beta corregido
XV	160	36	0.189284	1.867492	68 784.25	195 936.01
XVI	160	8	0.009020	116.413426	229.26	149 513.70

La Tabla 2 muestra cómo cambian los hiperparámetros cuando la experiencia colectiva se restringe a las celdas aplicables. En el procedimiento inicial, las causas XV y XVI utilizaban

todas las combinaciones disponibles de sexo, grupo etario y año. En el procedimiento corregido, la causa XV utiliza solamente mujeres de 10-14 a 50-54, mientras que la causa XVI utiliza solamente el grupo 0-4.

Para observar cómo el cambio en los hiperparámetros afecta las celdas individuales, se compara también la media posterior de la intensidad:

$$\mathbb{E} \left(\mu_{x,t,s}^{(c)} \mid D_{x,t,s}^{(c)} \right) = \frac{\hat{\alpha}_p^{(c)} + D_{x,t,s}^{(c)}}{\hat{\beta}_p^{(c)} + E_{x,t,s}}.$$

Tabla 3: Comparación de las medias posteriores de las intensidades en casos representativos.

Caso	Muer- tes	Exposi- ción	Media posterior inicial	Media posterior corregida
XV: hombre de 25-29	0	210 403	0.000000678	0.000000000
XV: mujer de 25-29	3	203 888	0.000011696	0.000012174
XVI: hombre de 0-4	143	176 002	0.000811485	0.000796931
XVI: hombre de 70-74	0	58 480	0.000000154	0.000000000

La Tabla 3 permite observar directamente el problema de la implementación inicial. Para la causa XV en un hombre de 25-29, la media posterior inicial es positiva aunque estos hombres presenten ceros estructurales. En el procedimiento corregido, la celda se encuentra fuera de $\mathcal{J}_p^{(XV)}$ y su intensidad se fija en cero.

Para una mujer de 25-29, la celda permanece dentro del dominio de la causa XV. Sin embargo, su media posterior cambia porque ahora los hiperparámetros se estiman sin incorporar las celdas masculinas ni los grupos etarios situados fuera del dominio.

En el caso de la causa XVI, la celda del grupo 0-4 permanece dentro del ajuste, pero su media posterior cambia al dejar de utilizarse las edades posteriores para estimar la experiencia colectiva. Por el contrario, la celda de 70-74 queda fuera del dominio adoptado para esta causa y su intensidad corregida se fija en cero.

1.4 Ordenamiento de los elementos del reporte

1.4.1. Identificación de los elementos primarios y secundarios

Primarios	Secundarios
Probabilidad actuarial de decremento por causa, ${}_nq_{x,t}^{(c)} = P(T_{x,t} \leq n, J = c)$.	Contexto general de la WHO Mortality Database y de su función en la recopilación internacional de defunciones por causa.
Teoría de decrementos múltiples de Bowers et al. (1997) y Deshmukh (2012).	Modelación actuarial mediante modelos de decremento presentada por Dirgová y Bilíková (2014).
Gráficos de Goerlich (2012).	Hallazgo de Calazans y Queiroz (2020) acerca de la existencia de patrones comunes de mortalidad adulta en América Latina, pero con cambios distintos entre países.
Modelo Poisson de Manton et al. (1989) para los conteos de defunciones.	Uso de la población a mitad de año como aproximación de la exposición $E_{x,t}$, de acuerdo con Pitacco et al. (2009).
Estimador clásico de Pitacco et al. (2009), $\hat{\mu}_{x,t}^{(c)} = D_{x,t}^{(c)} / E_{x,t}$.	Supuesto de fuerza de mortalidad constante dentro de cada celda formada por país, sexo, año calendario y grupo etario.
Idea Empirical Bayes de Zhang et al. (2019) para estimar $\hat{\alpha}_p^{(c)}$ y $\hat{\beta}_p^{(c)}$.	Resultado de Schmitt et al. (2019) sobre la distribución marginal binomial negativa obtenida al integrar la intensidad del modelo Poisson–Gamma.
Fuerza total de mortalidad obtenida mediante $\mu_{x,t}^{(\tau)} = \sum_{j=1}^r \mu_{x,t}^{(j)}$.	Interpretación de las causas de muerte como riesgos competitivos, donde la probabilidad de morir por una causa también depende de las intensidades de las demás causas.
Transformación de las intensidades en probabilidades de decremento mediante $q_{x,t}^{(c)} = \frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}}\right)$.	Fijación del horizonte en $n = 1$ para mantener la interpretación anual de las probabilidades y hacerla coherente con la estructura de los datos.
Estimador bayesiano $q_{x,t}^{(c)*} = \frac{1}{S} \sum_{k=1}^S q_{x,t}^{(c,k)} \approx \mathbb{E} \left(Q_{x,t}^{(c)} \mid \mathcal{D}_{x,t} \right)$.	Uso de la Ley de los Grandes Números para justificar la aproximación de la esperanza posterior mediante la media de las simulaciones.
Simulación paramétrica de conteos Poisson para obtener intervalos de confianza del enfoque clásico.	Elección de una misma cantidad de simulaciones y de un mismo nivel de cobertura para hacer comparables los intervalos clásicos y bayesianos.
Construcción de intervalos creíbles mediante los cuantiles de la distribución posterior de $Q_{x,t}^{(c)}$.	Diferencia interpretativa entre un intervalo de confianza clásico y un intervalo creíble bayesiano.

Primarios	Secundarios
Comparación entre $\hat{q}_{x,t}^{(c)}$ y $q_{x,t}^{(c)*}$ para un mismo país, sexo, año, grupo etario y causa.	Uso de diferencias absolutas, diferencias relativas y amplitudes de los intervalos como herramientas complementarias de comparación.
Análisis de cómo cambia $q_{x,t}^{(c)}$ conforme cambia el grupo etario.	Clasificación de las causas de muerte mediante los grupos amplios de la ICD-10 propuestos por la WHO.
Comparación de los perfiles de decremento por país, sexo, año y causa de muerte.	Calidad, cobertura y comparabilidad de los registros de mortalidad entre los países incluidos.
Análisis de la composición causal $\pi_{x,t}^{(c)} = P(J = c \mid T_{x,t} \leq 1)$	Distinción entre la probabilidad absoluta de decremento por causa y la distribución de las causas condicionada a que ocurra la muerte.
Identificación de las celdas en las que el enfoque clásico y el bayesiano producen resultados semejantes.	Resultado esperado de que ambas estimaciones se aproximen cuando existe una exposición grande y una cantidad suficiente de defunciones.
Tratamiento de los conteos nulos dentro del enfoque clásico y del enfoque bayesiano.	Distinción entre un cero observado, un cero estructural y una celda situada fuera del dominio de estimación definido para una causa.
Resultados sobre los patrones etarios de las probabilidades de decremento por las distintas categorías de causas.	Uso de gráficos de líneas, mapas de calor, gráficos radar y tablas resumen para facilitar la interpretación de los resultados.
Resultados sobre las diferencias de mortalidad por causa entre hombres y mujeres.	Consideración particular de la causa XV y XVI según el sexo y el rango etario aplicable.
Resultados sobre las diferencias entre países centroamericanos durante el periodo 2015–2018.	Exclusión de Honduras debido a la falta de observaciones recientes compatibles con el periodo definido para el proyecto.
Interpretación actuarial de los principales patrones encontrados para $q_{x,t}^{(c)}$.	Posibles implicaciones de los resultados para el estudio de la mortalidad por causa y la identificación de grupos con perfiles particulares.
Conclusiones sobre la variabilidad de la probabilidad de decremento y sobre la comparación entre los enfoques clásico y bayesiano.	Limitaciones relacionadas con la naturaleza agregada de los datos y con la imposibilidad de interpretar las estimaciones como riesgos individuales exactos.

Nuevas fichas de literatura

Título: *Empirical Bayes Procedures for Stabilizing Maps of U.S. Cancer Mortality Rates*

Autores: Kenneth G. Manton, Max A. Woodbury, Eric Stallard, Wilson B. Riggan, John P. Creason y Alvin C. Pellom.

Año: 1989.

Tema principal: Tasas de mortalidad mediante un procedimiento *Empirical Bayes*.

Clasificación: Metodológica, porque el artículo propone una forma concreta de estimar tasas de mortalidad cuando algunas poblaciones tienen pocos fallecimientos observados.

Resumen en una oración: Los autores utilizan un procedimiento *Empirical Bayes* para reducir la variabilidad de las tasas de mortalidad por cáncer calculadas en poblaciones pequeñas.

Argumento principal: Cuando una tasa de mortalidad se calcula con pocos fallecimientos o con una población expuesta pequeña, puede variar mucho por razones puramente aleatorias. Esto hace que algunas tasas parezcan demasiado altas o bajas, aunque en realidad el cambio se deba a la poca información disponible. Para enfrentar este problema, los autores combinan la experiencia observada en cada condado con información proveniente del conjunto de condados. Así, las poblaciones con mayor cantidad de información conservan estimaciones cercanas a su tasa observada, mientras que las poblaciones pequeñas reciben una mayor estabilización.

Relación con el proyecto: El artículo sirve como respaldo para modelar los conteos de defunciones mediante una distribución Poisson. En nuestro caso se plantea

$$D_{x,t}^{(c)} \mid \mu_{x,t}^{(c)} \sim \text{Poisson} \left(E_{x,t} \mu_{x,t}^{(c)} \right),$$

donde $D_{x,t}^{(c)}$ es el número de defunciones por la causa c , $E_{x,t}$ es la exposición y $\mu_{x,t}^{(c)}$ es la intensidad de mortalidad correspondiente.

También permite justificar la necesidad de estabilizar las estimaciones en celdas con poca exposición o con pocos fallecimientos. Esta situación aparece en nuestro proyecto principalmente en edades jóvenes, causas poco frecuentes y países con poblaciones pequeñas. En estos casos, la tasa clásica

$$\hat{\mu}_{x,t}^{(c)} = \frac{D_{x,t}^{(c)}}{E_{x,t}}$$

puede ser muy inestable. El enfoque *Empirical Bayes* permite que la estimación utilice tanto la información de la celda como la experiencia general observada para la misma causa.

Limitaciones para nuestro proyecto: El artículo estudia tasas de mortalidad por cáncer estandarizadas por edad y organizadas geográficamente por condados de Estados Unidos.

Nuestro proyecto, en cambio, trabaja con grupos etarios, países centroamericanos y varias categorías de causas de muerte. Además, el objeto final no es solamente la intensidad $\mu_{x,t}^{(c)}$, sino la probabilidad actuarial de decremento

$$q_{x,t}^{(c)} = \frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right), \quad \mu_{x,t}^{(\tau)} = \sum_{j=1}^r \mu_{x,t}^{(j)}.$$

Por esta razón, no utilizamos de manera completa el procedimiento desarrollado por los autores, sino principalmente su justificación del modelo Poisson y de la estabilización de tasas en poblaciones pequeñas.

Lo que el artículo no resuelve: No explica cómo combinar varias causas competidoras para obtener $q_{x,t}^{(c)}$, ni cómo trasladar la incertidumbre de las intensidades hacia las probabilidades de decremento. Tampoco considera restricciones específicas para causas que solo se modelan en ciertos sexos o grupos etarios.

Contraste con otras fuentes: Manton et al. aportan la motivación práctica para estabilizar tasas de mortalidad. Schmitt et al. (2019) permiten justificar con mayor detalle la estructura Poisson-Gamma y la distribución marginal binomial negativa.

Nivel de aplicabilidad: 4/5. El artículo es bastante útil para justificar la distribución Poisson y el uso de información colectiva, aunque su procedimiento completo no coincide con el que se implementa en el proyecto.

Pregunta para los autores: ¿Cómo se podría extender este procedimiento para estimar simultáneamente varias intensidades por causa cuando todas intervienen en una misma probabilidad de decremento?

Síntesis: El aporte principal de Manton et al. para nuestro proyecto es mostrar que las tasas calculadas con pocos fallecimientos no deberían interpretarse sin considerar su variabilidad. La idea de combinar la información particular de una celda con una experiencia más amplia permite obtener estimaciones menos extremas y más estables. Aunque el artículo no trabaja directamente con decrementos múltiples, su planteamiento sirve como antecedente para el modelo *Empirical Bayes* utilizado en la estimación de las intensidades.

Título: *A Class of Flat Prior Distributions for the Poisson-Gamma Hierarchical Model*

Autores: Fernando O. Schmitt, Gustavo L. Gilardoni y J. A. A. Andrade.

Año: 2019.

Tema principal: Propiedades del modelo jerárquico Poisson-Gamma y uso de distribuciones previas planas para sus hiperparámetros.

Clasificación: Teórica, porque el artículo se concentra en estudiar las condiciones matemáticas bajo las cuales la distribución posterior es válida y sus momentos existen.

Resumen en una oración: Los autores estudian una familia de previas planas para el modelo Poisson–Gamma y muestran las condiciones necesarias para obtener distribuciones posteriores propias.

Argumento principal: En un modelo jerárquico Poisson–Gamma algunas previas impropias pueden producir una posterior que tampoco sea propia o cuyos momentos no existan. Por esta razón, los autores analizan una familia amplia de distribuciones previas para los hiperparámetros y establecen las condiciones necesarias para que la inferencia posterior sea válida.

Durante este desarrollo también presentan una propiedad importante del modelo: cuando un conteo sigue una distribución Poisson condicionada a una tasa Gamma, la distribución marginal del conteo es binomial negativa.

Relación con el proyecto: En nuestro enfoque bayesiano se plantea

$$D_{x,t}^{(c)} \mid \mu_{x,t}^{(c)} \sim \text{Poisson} \left(E_{x,t} \mu_{x,t}^{(c)} \right),$$

junto con

$$\mu_{x,t}^{(c)} \sim \text{Gamma} \left(\alpha^{(c)}, \beta^{(c)} \right),$$

donde $\beta^{(c)}$ se interpreta como parámetro de tasa.

Al integrar la intensidad $\mu_{x,t}^{(c)}$, se obtiene la distribución marginal

$$P \left(D_{x,t}^{(c)} = d \right) = \frac{\Gamma \left(\alpha^{(c)} + d \right)}{\Gamma \left(\alpha^{(c)} \right) d!} \left(\frac{\beta^{(c)}}{\beta^{(c)} + E_{x,t}} \right)^{\alpha^{(c)}} \left(\frac{E_{x,t}}{\beta^{(c)} + E_{x,t}} \right)^d.$$

Esta expresión es importante porque permite construir la verosimilitud marginal utilizada para estimar $\alpha^{(c)}$ y $\beta^{(c)}$ a partir de los conteos observados.

Una vez estimados los hiperparámetros, la distribución posterior de la intensidad es

$$\mu_{x,t}^{(c)} \mid D_{x,t}^{(c)}, E_{x,t} \sim \text{Gamma} \left(\hat{\alpha}^{(c)} + D_{x,t}^{(c)}, \hat{\beta}^{(c)} + E_{x,t} \right).$$

Limitaciones para nuestro proyecto: El artículo estudia un enfoque bayesiano completo en el que también se asignan distribuciones previas a los hiperparámetros. En nuestro proyecto no se colocan hiperprevias sobre $\alpha^{(c)}$ y $\beta^{(c)}$, sino que estos parámetros se estiman mediante máxima verosimilitud marginal. Por tanto, la mayor parte de los resultados relacionados con previas planas y posterioridad propia no se utiliza directamente.

Además, los autores no trabajan con mortalidad, riesgos competitivos ni probabilidades actuariales de decremento.

Lo que el artículo no resuelve: No presenta el procedimiento *Empirical Bayes* específico utilizado en el proyecto ni explica cómo transformar varias intensidades posteriores en una distribución posterior para $q_{x,t}^{(c)}$. Tampoco estudia la simulación conjunta de las intensidades correspondientes a todas las causas.

Contraste con otras fuentes: Schmitt et al. aportan principalmente la parte matemática del modelo Poisson–Gamma. Manton et al. (1989) muestran por qué la estabilización resulta necesaria en datos de mortalidad.

Nivel de aplicabilidad: 3/5. La derivación de la distribución marginal binomial negativa es muy útil para nuestro modelo, pero buena parte del artículo trata problemas de hiperprevias que no se incorporan en el proyecto.

Pregunta para los autores: ¿Qué condiciones se necesitarían para garantizar la existencia de los momentos posteriores de $q_{x,t}^{(c)}$, considerando que esta probabilidad depende de todas las intensidades por causa?

Síntesis: Schmitt et al. no constituyen la principal referencia para justificar todo el enfoque *Empirical Bayes*, pero sí permiten fundamentar una parte matemática importante. En particular, muestran cómo surge la distribución binomial negativa al integrar una intensidad Gamma dentro de un modelo Poisson.

Título: *The Empirical Bayes Estimators of the Parameter of the Poisson Distribution with a Conjugate Gamma Prior under Stein’s Loss Function*

Autores: Ying-Ying Zhang, Ze-Yu Wang, Zheng-Min Duan y Wen Mi.

Año: 2019.

Tema principal: Estimación Empirical Bayes en un modelo jerárquico Poisson-Gamma.

Clasificación: Metodológica y teórica, porque el artículo desarrolla estimadores bayesianos para el parámetro de una distribución Poisson y estudia dos formas de estimar los hiperparámetros de la distribución Gamma: el método de momentos y la máxima verosimilitud.

Resumen en una oración: Los autores estiman los hiperparámetros de un modelo Poisson–Gamma mediante momentos y máxima verosimilitud, y utilizan esas estimaciones para construir estimadores *Empirical Bayes*.

Argumento principal: En un análisis *Empirical Bayes*, la distribución previa conserva una estructura paramétrica conocida, pero sus hiperparámetros se estiman a partir de los propios datos. Zhang et al. estudian el modelo

$$X_i \mid \theta_i \sim \text{Poisson}(\theta_i), \quad \theta_i \sim \text{Gamma}(\alpha, \beta),$$

donde α es el parámetro de forma y β el parámetro de tasa. Al integrar las variables θ_i , la distribución marginal de los conteos pertenece a la familia binomial negativa. Esta distribución marginal permite estimar α y β sin tener que observar directamente los parámetros θ_i .

Los autores comparan dos métodos para estimar los hiperparámetros. El primero utiliza los momentos muestrales y produce expresiones cerradas. El segundo maximiza la verosimilitud marginal y requiere métodos numéricos. En sus simulaciones, ambos métodos presentan un comportamiento consistente conforme aumenta el tamaño de muestra, pero la máxima verosimilitud suele producir mejores resultados que el método de momentos.

Relación con el proyecto: Este artículo es la referencia principal para justificar que los hiperparámetros de la distribución Gamma se estimen a partir de los conteos observados. En nuestro proyecto se plantea

$$D_{x,t}^{(c)} \mid \mu_{x,t}^{(c)} \sim \text{Poisson} \left(E_{x,t} \mu_{x,t}^{(c)} \right),$$

y

$$\mu_{x,t}^{(c)} \sim \text{Gamma} \left(\alpha^{(c)}, \beta^{(c)} \right).$$

La distribución previa conserva la forma Gamma, pero sus hiperparámetros $\alpha^{(c)}$ y $\beta^{(c)}$ no se escogen arbitrariamente. Siguiendo la lógica *Empirical Bayes* presentada por Zhang et al., estos se estiman usando la distribución marginal de las defunciones.

Al integrar la intensidad $\mu_{x,t}^{(c)}$, se obtiene

$$P \left(D_{x,t}^{(c)} = d \right) = \frac{\Gamma \left(\alpha^{(c)} + d \right)}{\Gamma \left(\alpha^{(c)} \right) d!} \left(\frac{\beta^{(c)}}{\beta^{(c)} + E_{x,t}} \right)^{\alpha^{(c)}} \left(\frac{E_{x,t}}{\beta^{(c)} + E_{x,t}} \right)^d.$$

Por tanto, los hiperparámetros se estiman mediante

$$\left(\hat{\alpha}^{(c)}, \hat{\beta}^{(c)} \right) = \arg \max_{\alpha^{(c)}, \beta^{(c)} > 0} \ell_c \left(\alpha^{(c)}, \beta^{(c)} \right),$$

donde ℓ_c es la log-verosimilitud marginal construida con todas las celdas incluidas para la causa c .

Una vez estimados los hiperparámetros, la distribución posterior de cada intensidad es

$$\mu_{x,t}^{(c)} \mid D_{x,t}^{(c)}, E_{x,t} \sim \text{Gamma} \left(\hat{\alpha}^{(c)} + D_{x,t}^{(c)}, \hat{\beta}^{(c)} + E_{x,t} \right).$$

De esta distribución se simulan las intensidades que posteriormente se transforman en probabilidades de decremento.

Adaptación necesaria: El modelo original de Zhang et al. supone conteos Poisson con media θ_i y no incorpora una exposición diferente para cada observación. En nuestro proyecto la media del conteo es

$$E_{x,t}\mu_{x,t}^{(c)},$$

por lo que las probabilidades de la distribución marginal dependen de $E_{x,t}$. Esto significa que las ecuaciones de máxima verosimilitud presentadas en el artículo no se utilizan literalmente. Se conserva su estrategia de estimar los hiperparámetros mediante la verosimilitud marginal, pero esta se modifica para incorporar las exposiciones de cada celda.

Limitaciones para nuestro proyecto: El artículo estima directamente el parámetro de una distribución Poisson, mientras que nuestro interés final es la probabilidad de decremento

$$q_{x,t}^{(c)} = \frac{\mu_{x,t}^{(c)}}{\mu_{x,t}^{(\tau)}} \left(1 - e^{-\mu_{x,t}^{(\tau)}} \right), \quad \mu_{x,t}^{(\tau)} = \sum_{j=1}^r \mu_{x,t}^{(j)}.$$

Zhang et al. tampoco trabajan con riesgos competitivos ni con varias intensidades que deban simularse de manera conjunta para calcular una misma cantidad.

Además, buena parte del artículo se centra en la función de pérdida de Stein. Bajo esta pérdida, el estimador propuesto para el parámetro Poisson es distinto de la media posterior. En nuestro proyecto, en cambio, el estimador de $q_{x,t}^{(c)}$ se obtiene bajo pérdida cuadrática y corresponde a su esperanza posterior, aproximada mediante simulación. Por tanto, la función de pérdida de Stein no forma parte de la metodología adoptada.

Lo que el artículo no resuelve: No explica cómo transformar varias intensidades posteriores en probabilidades de decremento por causa ni cómo obtener intervalos creíbles para estas probabilidades. Tampoco estudia la presencia de exposiciones distintas, grupos etarios, causas de muerte o restricciones del dominio de estimación.

Contraste con otras fuentes: Zhang et al. justifican de manera directa la estimación *Empirical Bayes* de los hiperparámetros mediante momentos y máxima verosimilitud. Schmitt et al. (2019) desarrollan con mayor profundidad las propiedades teóricas del modelo Poisson–Gamma y de las distribuciones previas para sus hiperparámetros. Manton et al. (1989) muestran una aplicación de *Empirical Bayes* a la estabilización de tasas de mortalidad.

Nivel de aplicabilidad: 5/5. Es la fuente más cercana al procedimiento utilizado para estimar $\alpha^{(c)}$ y $\beta^{(c)}$. No obstante, se requiere adaptar la verosimilitud marginal para incorporar la exposición $E_{x,t}$ y no se utiliza el estimador basado en la pérdida de Stein.

Pregunta para los autores: ¿Cómo cambiarían los estimadores de los hiperparámetros si cada conteo Poisson tuviera una exposición conocida y distinta, como ocurre con las defunciones y poblaciones de cada grupo etario?

Síntesis: El principal aporte de Zhang et al. para el proyecto es la idea de estimar los hiperparámetros de la distribución Gamma utilizando la distribución marginal de los conteos. Esto permite construir una previa a partir de la experiencia observada, en lugar de fijar sus parámetros de forma arbitraria. Los resultados del artículo también respaldan el uso de máxima verosimilitud sobre el método de momentos, aunque advierten que su cálculo es numérico, sensible a los valores iniciales y más costoso computacionalmente. En nuestro caso se adopta esta misma lógica, pero se modifica la verosimilitud para tomar en cuenta que cada celda tiene una exposición diferente.

Referencias

Manton, K. G., Woodbury, M. A., Stallard, E., Riggan, W. B., Creason, J. P., & Pellom, A. C. (1989). Empirical Bayes procedures for stabilizing maps of U.S. cancer mortality rates. *Journal of the American Statistical Association*, 84(407), 637–650. <https://doi.org/10.1080/01621459.1989.10478816>

Schmitt, F. O., Gilardoni, G. L., & Andrade, J. A. A. (2019). A class of flat prior distributions for the Poisson-gamma hierarchical model. *Statistica Neerlandica*, 73(3), 414–433. <https://doi.org/10.1111/stan.12176>

Zhang, Y.-Y., Wang, Z.-Y., Duan, Z.-M., & Mi, W. (2019). The empirical Bayes estimators of the parameter of the Poisson distribution with a conjugate gamma prior under Stein's loss function. *Journal of Statistical Computation and Simulation*, 89(16), 3061–3074. <https://doi.org/10.1080/00949655.2019.1652606>